



CONSERVATOIRE NATIONAL DES ARTS ET MÉTIERS

Master Finance de marché

**L'approche agentique dans un contexte de trading
multifactoriel**

État de l'art, architectures ouvertes et exigences d'explicabilité

Nom et prénom : SANOU Abou Dramane

Encadrant : Bertrand DJEMBISSI

Rapport d'étude présenté dans le cadre du Master Finance de marché

Paris, juin 2026

Résumé

Les desks de trading doivent industrialiser la recherche, le suivi des portefeuilles et la préparation des décisions tout en conservant un niveau élevé de contrôle, d'explicabilité et de traçabilité. Ce rapport étudie l'usage d'agents fondés sur des grands modèles de langage dans une architecture de trading multifactoriel, en distinguant ce qui peut être confié à un agent de ce qui doit rester déterministe.

L'étude combine un état de l'art des frameworks et projets GitHub avec un prototype expérimental. Le socle quantitatif utilise quatre ETF comme proxies investissables des facteurs value, momentum, quality et low volatility : VLUE, MTUM, QUAL et USMV. Une allocation équilibrée est comparée à l'ETF SPY sur la période février 2015-décembre 2025, avec des scénarios de coûts de transaction de 0, 10 et 30 points de base ainsi qu'un contrôle hors échantillon sur 2021-2025. Sur l'échantillon complet, le portefeuille multifactoriel à 10 points de base obtient un rendement annualisé de 12,10 %, contre 13,95 % pour SPY ; hors échantillon, les rendements sont respectivement de 11,45 % et 14,60 %. Le prototype ne démontre donc pas une capacité à générer de l'alpha.

La couche agentique est démontrée avec LangGraph sur deux dates de rééquilibrage, les 30 novembre et 31 décembre 2025. Elle lit les sorties structurées du moteur quantitatif, vérifie les contrôles, produit une note sourcée et demande une validation humaine. Elle ne recalcule pas les métriques, ne modifie pas les pondérations et ne peut pas envoyer d'ordre. Le résultat principal est architectural : les agents sont utiles pour l'orchestration, l'interprétation et la documentation, tandis que les facteurs, le risque, les permissions et la décision finale doivent rester contrôlés par des règles vérifiables.

Mots-clés :

agents intelligents, trading multifactoriel, finance de marché, LLM, explicabilité, gouvernance des modèles, GitHub, backtesting, LangGraph.

Abstract

Trading desks seek to industrialize research, portfolio monitoring and decision preparation while preserving strong controls, explainability and auditability. This report studies large language model agents in a multifactor trading architecture and distinguishes tasks that may be delegated to an agent from tasks that must remain deterministic.

The study combines a review of open-source frameworks and finance-oriented GitHub projects with an empirical prototype. The quantitative layer uses four exchange-traded funds as investable proxies for value, momentum, quality and low-volatility factors : VVALUE, MTUM, QUAL and USMV. An equal-weighted portfolio is compared with SPY over February 2015-December 2025, under 0, 10 and 30 basis-point transaction-cost scenarios, with an out-of-sample check over 2021-2025. Over the full sample, the 10-basis-point multifactor portfolio achieves a 12.10% annualized return versus 13.95% for SPY ; out of sample, the corresponding figures are 11.45% and 14.60%. The experiment therefore does not establish alpha generation.

The agentic layer is demonstrated with LangGraph on two rebalancing dates, 30 November and 31 December 2025. It reads structured quantitative outputs, checks quality and risk gates, produces a traceable note and requests human validation. It does not recompute metrics, change portfolio weights or send orders. The main contribution is architectural : agents can support orchestration, interpretation and documentation, while factors, risk, permissions and final decisions must remain governed by verifiable rules.

Keywords :

intelligent agents, multifactor trading, market finance, LLM, explainability, model governance, GitHub, backtesting, LangGraph.

Remerciements

Je remercie mon encadrant, Bertrand DJEMBISSI, pour son accompagnement et ses orientations dans la préparation de ce rapport d'étude. Je remercie également l'équipe pédagogique du CNAM pour le cadre de formation fourni au sein du Master Finance de marché.

Table des matières

	Page
Résumé	i
Abstract	iii
Remerciements	iv
Liste des figures	ix
Liste des tableaux	xi
Glossaire	xi
1 Introduction et problématique	1
1.1 Contexte général	1
1.2 Problématique	2
1.3 Objectifs du rapport	3
1.4 Périmètre	3
1.5 Organisation du rapport	4
2 État de l’art et solutions GitHub	5
2.1 Définir l’approche agentique	5
2.2 État des lieux synthétique du domaine	6
2.3 Trading multifactoriel : chaîne quantitative de référence	7
2.4 Frameworks généralistes d’agents	7

2.5	Plateformes quantitatives et briques de trading ouvertes	8
2.6	Fiches techniques des briques retenues	9
2.6.1	LangGraph : orchestration et état	9
2.6.2	Qlib : recherche quantitative et backtesting	10
2.6.3	OpenBB : accès aux données et veille	10
2.7	Projets GitHub spécifiquement agentiques en finance	10
2.8	Critères observables et statut dans le mémoire	11
2.9	Lecture critique de l'état de l'art	12
3	Méthodologie d'analyse	14
3.1	Démarche documentaire	14
3.2	Revue réglementaire arrêtée au 30 août 2026	15
3.3	Grille d'évaluation et scoring	16
3.4	Principes de conception	17
3.5	Méthode de classement des solutions	18
3.6	Protocole expérimental	18
3.7	Limites de la méthode	20
4	Architecture cible pour un desk multifactoriel agentique	21
4.1	Principe directeur	21
4.2	Vue d'ensemble de l'architecture	21
4.3	Socle quantitatif déterministe	22
4.4	Agents proposés	23
4.5	Flux de décision et boucle de rejet	24
4.6	Journal de décision explicable	26
4.7	Monitoring continu	27
4.8	Exemple de scénario de rééquilibrage	28
5	Discussion et analyse critique	29
5.1	Apports de l'approche agentique	29
5.2	Risques spécifiques	30

5.3	Explicabilité : trois niveaux	30
5.3.1	Explicabilité quantitative	30
5.3.2	Explicabilité agentique	30
5.3.3	Explicabilité de la décision finale	31
5.4	Positionnement des solutions GitHub	31
5.5	Conditions minimales de mise en production	32
5.6	Résultats du prototype expérimental	32
5.7	Démonstration de la couche agentique	34
5.8	Synthèse	35
6	Conclusion	36
6.1	Réponse à la problématique	36
6.1.1	Les tâches pour lesquelles les agents sont utiles	36
6.1.2	Les tâches qui doivent rester déterministes	37
6.1.3	Les mécanismes de traçabilité et de contrôle	37
6.2	Résultats du prototype	37
6.3	Limites	38
6.4	Perspectives	38
	Bibliographie	40
	Annexes	44
I	Matrice des solutions GitHub	45
I.1	Solutions recommandées pour l'étude comparative	45
I.2	Due diligence des dépôts au 30 août 2026	46
I.3	Statut d'utilisation dans le mémoire	47
I.4	Combinaison minimale	48
II	Checklist de gouvernance d'un agent de trading	49
II.1	Avant expérimentation	49
II.2	Pendant le backtesting	49

II.3	Avant passage en observation	50
II.4	Avant toute exécution réelle	50

Liste des figures

	Page
3.1 Déroulement du protocole expérimental et contrôle hors échantillon.	20
4.1 Architecture cible séparant le socle quantitatif, les agents et la gouvernance. .	22
4.2 Permissions, escalades et interdictions dans la couche agentique.	24
4.3 Séquence de décision avec boucle de rejet par le contrôle risque.	25
4.4 Extrait réel du journal JSON produit par le prototype.	26
4.5 Monitoring agentique et réactions en cas de dépassement de seuil.	27
5.1 Trois niveaux d’explicabilité reliés au journal d’audit.	31
5.2 Évolution d’un investissement initial de 100 unités.	33
5.3 Drawdown du benchmark et des portefeuilles multifactoriels.	34

Liste des tableaux

	Page
2.1 Frameworks agentiques généralistes disponibles sur GitHub.	8
2.2 Briques quantitatives GitHub utiles pour une étude multifactorielle.	9
2.3 Solutions GitHub orientées agents financiers.	11
2.4 Critères observables et statut des principales solutions.	12
3.1 Grille de scoring des solutions agentiques et quantitatives.	16
3.2 Scoring documentaire provisoire des dépôts retenus.	17
4.1 Rôles, permissions et limites des agents proposés.	23
4.2 Séquence de décision et conditions de rejet.	25
4.3 Métriques agentiques, seuils d’alerte et réactions.	27
5.1 Risques agentiques, contrôles et responsabilités.	30
5.2 Résultats du prototype multifactoriel et du benchmark.	33
5.3 Contrôle hors échantillon sur la période 2021-2025.	33
5.4 Évaluation des deux démonstrations agentiques.	35
I.1 Matrice de sélection des dépôts GitHub.	46
I.2 Grille de due diligence des briques sélectionnées.	47
I.3 Statut des solutions dans le travail réalisé.	48

Glossaire

API interface de programmation applicative.

DORA Digital Operational Resilience Act.

ES expected shortfall.

ETF fonds indiciel coté.

HFT trading haute fréquence.

HITL human-in-the-loop.

IA intelligence artificielle.

LLM grand modèle de langage.

MAR Market Abuse Regulation.

MiFID II Markets in Financial Instruments Directive II.

PnL profit and loss.

RAG génération augmentée par récupération.

RL apprentissage par renforcement.

VaR valeur en risque.

Chapitre 1

Introduction et problématique

1.1 Contexte général

Le trading multifactoriel consiste à construire des décisions d'investissement à partir de plusieurs familles de signaux : valorisation, momentum, qualité, faible volatilité, liquidité, portage, révisions d'analystes, signaux macroéconomiques ou signaux issus de nouvelles. Cette logique prolonge la tradition académique des modèles factoriels, depuis les facteurs de marché, taille et valeur de [Fama and French \(1993\)](#) jusqu'au facteur momentum formalisé par [Carhart \(1997\)](#). Dans un contexte professionnel, ces facteurs ne suffisent pas à eux seuls : ils doivent être nettoyés, normalisés, neutralisés, testés hors échantillon, combinés avec des contraintes de risque, puis traduits en ordres compatibles avec la liquidité et le mandat du portefeuille.

Les avancées récentes des grands modèles de langage ont introduit une nouvelle brique dans cette chaîne. Un agent ne se limite pas à produire du texte : il peut appeler des outils, lire des documents, interroger une base de données, déléguer des tâches à d'autres agents et enregistrer les raisons d'une décision. Les travaux sur ReAct ([Yao et al., 2023](#)), Toolformer ([Schick et al., 2023](#)), Reflexion ([Shinn et al., 2023](#)) et AutoGen ([Wu et al., 2023](#)) ont montré que le raisonnement, l'utilisation d'outils et l'interaction multi-agents peuvent être assemblés en workflows plus robustes qu'un simple prompt isolé.

Pour un desk de trading, cette évolution ouvre des cas d'usage concrets : veille de marché, qualification de nouvelles, synthèse de recherche, génération de scénarios, préparation

de revues de risque, documentation des décisions, contrôle de cohérence d’une stratégie et assistance au backtesting. En revanche, elle ne supprime pas les exigences fondamentales de la finance de marché : contrôle du risque, séparation des responsabilités, validation indépendante, explicabilité, auditabilité et surveillance continue.

1.2 Problématique

La question centrale de ce rapport est la suivante : comment utiliser une approche agentic dans un environnement de trading multifactoriel sans transformer un outil d’aide à la décision en boîte noire opérationnelle ? Cette question est plus exigeante que la simple automatisation d’un script de trading. Un agent fondé sur un LLM peut produire une justification plausible sans que cette justification soit causalement liée au signal réellement utilisé. Il peut aussi confondre une corrélation historique avec une relation exploitable, ignorer une limite de risque ou synthétiser une nouvelle de marché sans mesurer son impact probabiliste.

Le domaine est fortement réglementé. En Europe, les exigences relatives au trading algorithmique imposent des systèmes résilients, des contrôles de risque et des limites permettant d’éviter des conditions de marché désordonnées ([European Securities and Markets Authority, 2026](#)). Le règlement DORA renforce les obligations liées au risque informatique et à la résilience opérationnelle des entités financières ([European Parliament and Council of the European Union, 2022](#)). Les cadres de gestion des risques liés à l’IA, comme le NIST AI Risk Management Framework, insistent sur la gouvernance, la mesure, la cartographie des risques et le monitoring ([Tabassi, 2023](#)). Même lorsque l’usage n’entre pas automatiquement dans une catégorie d’IA à haut risque au sens de l’AI Act ([European Parliament and Council of the European Union, 2024](#)), les principes de contrôle, de documentation et de surveillance restent indispensables dans une institution financière.

La problématique peut donc être formulée ainsi : quelles architectures agentiques disponibles aujourd’hui, notamment sur GitHub, peuvent contribuer à un desk de trading multifactoriel explicable, rationnel et monitorable, et quelles limites empêchent encore leur déploiement autonome en production ?

1.3 Objectifs du rapport

Ce rapport poursuit cinq objectifs :

1. établir un état de l’art des architectures agentiques pertinentes pour la finance de marché ;
2. recenser les projets GitHub qui peuvent être mobilisés pour analyser l’état actuel des architectures agentiques en finance de marché ;
3. comparer ces projets selon des critères observables : gestion de l’état, persistance, supervision humaine, permissions d’outils, reprise après incident, mémoire, backtesting et traçabilité ;
4. proposer une architecture cible dans laquelle les agents assistent la décision sans remplacer les contrôles quantitatifs et humains nécessaires ;
5. expérimenter un socle quantitatif et une couche agentique supervisée afin d’évaluer la reproductibilité des calculs, la fidélité des synthèses et le respect des permissions.

1.4 Périmètre

Le rapport se concentre sur les actions liquides, ETF, futures et crypto-actifs comme univers d’étude pour les solutions ouvertes. Les produits complexes, l’optimisation fiscale, le trading haute fréquence et les infrastructures propriétaires d’exécution ne sont pas étudiés en détail.

Le travail ne vise pas à construire une plateforme de trading prête pour la production, à démontrer une capacité à générer de l’alpha ou à proposer un dispositif réglementaire complet. Il valide certains principes architecturaux à travers un prototype expérimental : séparation entre calcul et interprétation, contrôle hors échantillon, journalisation structurée, permissions limitées et validation humaine. Les résultats financiers sont donc des résultats de démonstration et non une recommandation d’investissement.

L’analyse distingue trois niveaux :

Agents généralistes : frameworks permettant de coordonner des rôles, outils, mémoires et workflows.

Briques quantitatives : bibliothèques de données, backtesting, recherche factorielle, apprentissage par renforcement et exécution simulée.

Applications financières agentiques : dépôts combinant LLM, analyse financière et décision d'investissement.

1.5 Organisation du rapport

Le chapitre 2 présente l'état de l'art et la cartographie des solutions GitHub. Le chapitre 3 décrit la méthode de sélection et d'évaluation. Le chapitre 4 propose une architecture cible multi-agents adaptée au trading multifactoriel. Le chapitre 5 discute les risques, les limites et les conditions de mise en production. Le chapitre 6 conclut et propose des pistes d'approfondissement.

Chapitre 2

État de l’art et solutions GitHub

2.1 Définir l’approche agentique

Dans ce rapport, une architecture agentique désigne un système dans lequel un ou plusieurs agents combinent quatre capacités : compréhension du contexte, raisonnement, appel d’outils et mémoire. Un agent peut donc lire une nouvelle de marché, interroger une base de prix, calculer un indicateur, demander une vérification à un autre agent, puis produire une trace de décision. Cette définition est plus restrictive qu’un simple chatbot et plus large qu’un algorithme quantitatif classique.

Les architectures récentes s’appuient sur plusieurs idées issues de la littérature :

- le raisonnement et l’action alternés, illustrés par ReAct, où le modèle explicite une étape de raisonnement avant d’appeler un outil ([Yao et al., 2023](#));
- l’utilisation d’outils externes, popularisée par Toolformer et les frameworks d’agents modernes ([Schick et al., 2023](#));
- la génération augmentée par récupération, qui force le modèle à s’appuyer sur une base documentaire ou une source de données plutôt que sur sa seule mémoire paramétrique ([Lewis et al., 2020](#));
- la réflexion et l’amélioration itérative, où un agent critique sa propre sortie ou celle d’un autre agent ([Shinn et al., 2023](#));
- la collaboration multi-agents, où plusieurs rôles spécialisés dialoguent pour résoudre une tâche complexe ([Wu et al., 2023](#)).

Ces idées sont pertinentes pour le trading multifactoriel, mais elles ne doivent pas être confondues avec une validation financière. Un agent peut améliorer la productivité de recherche sans prouver la robustesse d’un signal. La preuve d’une stratégie reste empirique : données propres, protocole de backtesting, prise en compte des coûts, stabilité hors échantillon, stress tests et limites de risque.

2.2 État des lieux synthétique du domaine

Le diagnostic fait apparaître un domaine encore fragmenté. Les solutions agentiques progressent rapidement, mais la plupart restent des cadres de coordination ou des démonstrateurs. Les briques quantitatives sont plus matures pour les calculs, les données et le backtesting, mais elles ne couvrent pas la gouvernance propre aux agents LLM. Les solutions les plus proches du trading agentique financier montrent des architectures intéressantes, mais leur niveau de contrôle, de documentation et de validation reste insuffisant pour une institution régulée.

1. **Maturité agentique** : les frameworks généralistes sont utiles pour organiser des rôles et des workflows, mais ils demandent une forte spécialisation métier.
2. **Maturité quantitative** : les plateformes de backtesting et de recherche disposent de bases solides, mais leur intégration avec des agents explicables reste partielle.
3. **Maturité réglementaire** : les dépôts ouverts traitent rarement la traçabilité, les droits par rôle, la validation indépendante et le suivi continu avec le niveau attendu en finance de marché.
4. **Maturité documentaire** : la littérature académique décrit les mécanismes de raisonnement, de mémoire et de collaboration, tandis que les dépôts GitHub illustrent surtout des usages exploratoires.

Cet état des lieux conduit à étudier les solutions comme des briques complémentaires plutôt que comme des produits prêts à déployer. La question pertinente devient donc moins « quel outil installer ? » que « quelle combinaison de briques permettrait de respecter les exigences de contrôle, de risque et de preuve ? »

2.3 Trading multifactoriel : chaîne quantitative de référence

Une chaîne multifactorielle standard comporte plusieurs étapes. D’abord, l’univers d’investissement est défini : actions liquides, ETF, futures, devises ou crypto-actifs. Ensuite, les données sont collectées : prix, volumes, fondamentaux, nouvelles, données macroéconomiques et éventuellement signaux alternatifs. Les facteurs sont calculés, winsorisés, normalisés, neutralisés par secteur ou par bêta, puis combinés dans un score agrégé. Le portefeuille est construit sous contraintes : exposition nette, volatilité, tracking error, turnover, liquidité, concentration, coûts et restrictions du mandat.

Dans cette chaîne, les agents peuvent jouer trois rôles utiles :

1. **assistance à la recherche**, en synthétisant des publications, en proposant des hypothèses de facteurs ou en détectant des ruptures de régime ;
2. **orchestration de workflow**, en lançant des scripts de calcul, en contrôlant la présence des données, en comparant les résultats et en générant un journal ;
3. **supervision explicable**, en résumant pourquoi une allocation est proposée, quels facteurs contribuent au signal et quelles limites de risque sont proches d’être atteintes.

Le rôle le plus risqué est la génération automatique d’ordres. Dans un cadre régulé, l’agent ne doit pas être l’unique décideur. Il doit produire une recommandation traçable, soumise à des règles déterministes et à une validation humaine ou algorithmique indépendante.

2.4 Frameworks généralistes d’agents

Les frameworks généralistes ne sont pas propres à la finance, mais ils fournissent les mécanismes d’orchestration nécessaires : définition de rôles, graphes d’étapes, appels d’outils, mémoire, validation de sorties et supervision humaine.

TABLE 2.1. Frameworks agentiques généralistes disponibles sur GitHub.

Projet GitHub	Positionnement	Intérêt pour un desk multifactoriel	Limites principales
LangGraph (LangChain AI, 2026)	Workflows d’agents sous forme de graphes, avec état persistant et contrôle fin des transitions.	Adapté aux processus audités : ingestion, calcul de facteurs, revue de risque, validation, journalisation.	Nécessite de développer les outils quantitatifs et les contrôles métier autour du graphe.
AutoGen (Microsoft, 2026a)	Conversations multi-agents et orchestration d’équipes d’agents.	Utile pour comparer des rôles de recherche, analyste, contrôleur de risque et superviseur.	Les conversations libres doivent être fortement contraintes pour un usage régulé.
CrewAI (CrewAI Inc., 2026)	Agents orientés rôles, tâches et processus.	Simple pour construire une équipe d’agents de recherche de marché et de reporting.	Moins adapté seul aux workflows critiques nécessitant des états vérifiables et des garde-fous stricts.
Semantic Kernel (Microsoft, 2026c)	SDK Microsoft pour connecter modèles, plugins, fonctions et mémoire.	Intéressant dans un environnement d’entreprise déjà Microsoft, avec intégration possible à des services internes.	L’architecture de trading reste à construire ; le framework ne fournit pas de modèle financier.
CAMEL (CAMEL-AI, 2026)	Environnements et méthodes pour sociétés multi-agents.	Pertinent pour expérimenter des interactions entre analystes spécialisés.	Plus orienté recherche agentique que production financière.
OpenAI Swarm (OpenAI, 2026)	Exemple éducatif de routage entre agents.	Montre clairement la logique de transfert entre rôles.	Projet expérimental, insuffisant pour une architecture de production.

La conclusion de cette première famille est claire : ces outils permettent d’orchestrer des agents, mais ils ne fournissent ni données financières robustes, ni moteur de backtesting, ni calcul de risque, ni conformité métier. Leur valeur réside dans la coordination et la traçabilité du workflow, à condition de les connecter à des briques quantitatives vérifiées.

2.5 Plateformes quantitatives et briques de trading ouvertes

La seconde famille regroupe les projets open source qui traitent réellement les données de marché, les portefeuilles, le backtesting ou l’exécution simulée. Ces projets ne sont pas forcément agentiques, mais ils constituent le socle déterministe auquel les agents doivent se connecter.

TABLE 2.2. Briques quantitatives GitHub utiles pour une étude multifactorielle.

Projet GitHub	Fonction principale	Apport dans l’architecture cible	Point d’attention
Qlib (Microsoft, 2026b)	Plateforme Microsoft orientée recherche quantitative, données, modèles et backtesting.	Bon socle pour tester des facteurs, pipelines de données et modèles prédictifs.	Adaptation nécessaire aux données internes et aux contraintes de portefeuille réelles.
FinRL (AI4Finance Foundation, 2026b) et FinRL-Meta (AI4Finance Foundation, 2026c)	Apprentissage par renforcement pour trading automatisé et environnements de marché.	Utile pour comparer une approche agentique LLM avec des agents RL plus classiques.	Le RL financier souffre fortement du surapprentissage et des coûts de transaction mal modélisés.
FinRL-X (Yang et al., 2026)	Infrastructure modulaire récente pour trading quantitatif natif IA.	Intéressant comme direction d’évolution vers une infrastructure plus intégrée.	Projet récent : maturité opérationnelle à vérifier avant usage critique.
QuantConnect Lean (QuantConnect, 2026)	Moteur open source de backtesting et trading algorithmique multi-actifs.	Brique robuste pour simuler et exécuter des stratégies dans un cadre contrôlé.	L’agent doit rester au-dessus du moteur, sans contourner les règles d’exécution.
OpenBB (OpenBB Finance, 2026)	Plateforme ouverte d’accès aux données et analyses financières.	Source pratique pour créer un agent de recherche et de veille.	La qualité dépend des fournisseurs de données configurés et de leurs licences.
Freqtrade (Freqtrade, 2026)	Bot de trading crypto avec backtesting et hyperoptimisation.	Utile pour une étude sur crypto-actifs, où l’accès aux données et échanges est simple.	Domaine crypto moins représentatif des contraintes actions institutionnelles.

Ces plateformes montrent qu’un système agentique sérieux doit s’appuyer sur des composants quantitatifs non génératifs. Le calcul d’un score factoriel, d’une volatilité ex ante, d’une contribution au risque ou d’un coût de transaction ne doit pas être laissé au LLM. Le LLM peut expliquer, vérifier, synthétiser et coordonner, mais le calcul financier doit rester reproductible.

2.6 Fiches techniques des briques retenues

Les trois briques retenues pour le prototype couvrent des fonctions différentes et ne doivent pas être présentées comme interchangeables.

2.6.1 LangGraph : orchestration et état

LangGraph représente le workflow sous la forme d’un graphe d’états et de transitions. Chaque nœud peut lire une entrée structurée, appeler un outil contrôlé et produire une sortie

validable avant de transmettre l’état au nœud suivant ([LangChain AI, 2026](#)). Cette organisation facilite les arrêts sur anomalie, la reprise après incident, la supervision humaine et la conservation d’une trace. Elle ne fournit toutefois ni données de marché, ni facteur financier, ni limite de risque : ces fonctions doivent rester dans des outils déterministes.

2.6.2 Qlib : recherche quantitative et backtesting

Qlib constitue une brique de recherche quantitative : préparation des données, création de signaux, entraînement de modèles et backtesting ([Microsoft, 2026b](#)). Son intérêt pour le rapport réside dans la séparation entre pipeline de recherche et orchestration agentique. Dans une architecture réelle, les données point-in-time, les coûts, les contraintes de portefeuille et la validation hors échantillon doivent être contrôlés indépendamment du modèle utilisé.

2.6.3 OpenBB : accès aux données et veille

OpenBB peut alimenter une couche de recherche et de veille par l’accès à plusieurs fournisseurs de données ([OpenBB Finance, 2026](#)). Le choix d’un fournisseur, sa licence, sa disponibilité historique et ses conditions d’utilisation doivent être enregistrés avec chaque sortie. OpenBB peut donc fournir un outil à un agent de recherche, mais ne constitue pas à lui seul une preuve de qualité des données ni un moteur de décision.

2.7 Projets GitHub spécifiquement agentiques en finance

La troisième famille est la plus proche du sujet : des dépôts qui utilisent directement des LLM ou des agents pour l’analyse financière, la recherche actions ou la décision de trading.

TABLE 2.3. Solutions GitHub orientées agents financiers.

Projet GitHub	Principe	Ce qu’il apporte au sujet	Limite pour un desk régulé
TradingAgents (Tauric Research, 2026)	Framework multi-agents imitant une société de trading avec analystes spécialisés, trader et gestion du risque.	C’est l’un des dépôts les plus proches de l’idée d’équipe multi-agents appliquée au trading.	À analyser comme démonstrateur de recherche ; il faut ajouter validation des données, limites de risque, audit et contrôle humain.
FinRobot (AI4Finance Foundation, 2026d)	Plateforme d’agents LLM pour applications financières, notamment recherche actions, analyse et valorisation.	Utile pour automatiser des tâches d’analyste financier et produire des synthèses structurées.	Plus orienté analyse et reporting que génération robuste d’ordres multifactoriels.
FinMem (Yu et al., 2023 ; FinMem contributors, 2026)	Agent de trading fondé sur mémoire stratifiée et profils de décision.	Montre l’intérêt de la mémoire long terme pour contextualiser les décisions de trading.	Les performances expérimentales ne suffisent pas à prouver une robustesse exploitable en production.
AI Hedge Fund (Patel, 2026)	Démonstrateur open source d’un fonds simulé composé d’agents d’investissement.	Bon support pédagogique pour comprendre la division des rôles entre analystes et gestionnaire.	Le dépôt se présente comme preuve de concept, pas comme outil de trading réel.
FinGPT (Yang et al., 2023 ; AI4Finance Foundation, 2026a)	Écosystème de modèles de langage financiers open source.	Peut servir de base de modèle ou de fine-tuning pour des agents spécialisés finance.	Un modèle financier n’est pas une architecture de décision ; il faut ajouter outils, gouvernance et backtesting.

Ces projets démontrent la faisabilité technique d’une approche multi-agents, mais leur maturité varie fortement. Les plus intéressants pour ce rapport ne sont pas ceux qui promettent une performance de trading, mais ceux qui rendent explicites les rôles : analyste fondamental, analyste technique, analyste sentiment, contrôleur du risque, trader et superviseur. Cette séparation facilite l’audit, car chaque agent peut être évalué sur une tâche précise.

2.8 Critères observables et statut dans le mémoire

Les tableaux précédents décrivent le positionnement général des outils. Pour rendre la comparaison vérifiable, l’analyse retient aussi des éléments observables : gestion de l’état et persistance, supervision humaine, permissions d’outils, reprise après incident, mémoire, backtesting, traçabilité, documentation et tests. Le statut de chaque brique est explicité afin de distinguer ce qui a été exécuté de ce qui a seulement été étudié.

TABLE 2.4. Critères observables et statut des principales solutions.

Brique	Éléments observables	Statut	Rôle dans le mémoire
LangGraph	État, transitions, persistance, arrêts, supervision humaine, permissions et trace des sorties.	Utilisée dans le prototype	Orchestration de la démonstration agentique et génération des notes.
Qlib	Pipeline de données, recherche factorielle, backtesting, reproductibilité des expériences.	Référence étudiée	Comparaison du socle quantitatif ; non utilisé dans le calcul final.
Lean	Backtesting multi-actifs, contraintes, simulation de l’exécution et extensibilité.	Référence comparative	Option d’évolution pour un moteur de simulation plus complet.
OpenBB	Accès à des fournisseurs, provenance des données, disponibilité historique et licences.	Référence étudiée	Exemple de brique pour un agent de veille ; non branchée au prototype.
TradingAgents et Fin-Robot	Découpage des rôles, mémoire, synthèse, appels d’outils et décision multi-agents.	Étudiés, non exécutés	Comparaison des architectures financières agentiques.
FinRL et Freqtrade	Environnements de backtesting, apprentissage ou exécution simulée.	Étudiés, non retenus	Solutions utiles dans d’autres périmètres, mais non nécessaires au prototype ETF.

2.9 Lecture critique de l’état de l’art

Aucune des solutions examinées ne couvre seule les besoins d’un desk régulé. Les frameworks généralistes savent gérer des états, des transitions ou des appels d’outils, mais ils ne fournissent pas un modèle de risque ni une preuve de qualité des données. Les plateformes quantitatives calculent et backtestent avec davantage de reproductibilité, mais elles ne résolvent pas la supervision d’un agent, la justification d’une synthèse ou la gouvernance des permissions. Les applications financières agentiques rapprochent ces deux dimensions, sans fournir pour autant le niveau de validation, de résilience et d’audit attendu en production.

Cette absence de solution intégrée n’est pas seulement une limite logicielle : elle détermine la méthode de conception. Les composants doivent être traités comme des briques complémentaires. Le moteur factoriel, l’optimiseur, les contrôles de risque et le calcul des coûts forment un socle déterministe. Les agents peuvent exploiter ce socle pour rechercher des informations, comparer des scénarios, détecter une incohérence, expliquer une sortie ou préparer une décision. Ils ne doivent pas pouvoir modifier silencieusement les paramètres calculés ni contourner une limite.

La comparaison des critères observables conduit ainsi à privilégier une architecture composée plutôt qu’un produit unique. LangGraph est retenu pour son contrôle du workflow et de

l'état ; les plateformes comme Qlib, Lean et OpenBB servent de références pour les données et le backtesting ; les projets TradingAgents, FinRobot et FinMem éclairent le découpage des rôles et la mémoire. Ce choix est cohérent avec le prototype : l'évaluation porte sur la séparation des responsabilités et la traçabilité, non sur une promesse de performance commerciale.

Chapitre 3

Méthodologie d'analyse

3.1 Démarche documentaire

L'état de l'art a été construit à partir de trois types de sources. Les sources académiques servent à comprendre les concepts : agents LLM, raisonnement avec outils, génération augmentée par récupération, mémoire, collaboration multi-agents et modèles factoriels. Les sources réglementaires servent à fixer les contraintes minimales d'un contexte financier : contrôle du trading algorithmique, résilience opérationnelle, gouvernance du risque IA et auditabilité. Enfin, les dépôts GitHub servent à identifier les solutions réellement disponibles et leur degré de maturité. Lorsque les documents étaient librement accessibles en PDF, ils ont été archivés dans le sous-dossier papers afin de constituer un corpus documentaire local. Les articles soumis à licence éditeur restent cités en bibliographie sans copie locale.

La recherche GitHub a été structurée autour de mots-clés : *LLM agent trading*, *multi-agent financial trading*, *financial LLM agent*, *quantitative trading framework*, *backtesting engine*, *FinRL*, *Qlib*, *OpenBB*, *LangGraph*, *AutoGen* et *CrewAI*. Les dépôts retenus devaient satisfaire au moins l'un des critères suivants :

- fournir une brique d'orchestration agentique ;
- traiter explicitement un cas d'usage financier ;
- fournir une infrastructure utile au trading multifactoriel : données, backtesting, moteur d'exécution simulée, apprentissage par renforcement ou recherche quantitative ;
- rendre le code accessible publiquement pour étude, adaptation ou expérimentation.

Le corpus de comparaison comprend 17 fiches : 6 frameworks généralistes, 6 briques quantitatives et 5 projets spécifiquement financiers. Huit dépôts ont ensuite été retenus pour la due diligence finale, tandis que les autres ont été conservés comme références comparatives ou écartés du prototype. Ce décompte porte sur les fiches étudiées et non sur une mesure exhaustive de tous les dépôts repérés. Les dépôts trop éloignés du sujet, purement marketing, sans code exploitable ou uniquement centrés sur des signaux isolés ont été écartés. Les informations sur GitHub doivent être réévaluées avant toute mise en production, car l'activité, la licence, les dépendances et les mainteneurs peuvent évoluer rapidement.

3.2 Revue réglementaire arrêtée au 30 août 2026

Cette revue est documentaire et ne constitue pas un avis juridique. Elle sert à relier l'architecture proposée aux sources officielles disponibles à la date d'arrêt.

- **MiFID II, article 17** : le trading algorithmique implique des systèmes et contrôles de risque adaptés, des limites, des tests et une capacité à décrire les paramètres et contrôles à l'autorité compétente ([European Securities and Markets Authority, 2026](#)).
- **DORA** : le règlement (UE) 2022/2554 s'applique depuis le 17 janvier 2025 et renforce la résilience opérationnelle numérique des entités financières ([European Parliament and Council of the European Union, 2022](#)).
- **AI Act** : le règlement (UE) 2024/1689 s'applique en principe depuis le 2 août 2026, avec des dates spécifiques pour certaines dispositions, notamment le 2 février 2025, le 2 août 2025 et le 2 août 2027 ([European Parliament and Council of the European Union, 2024](#)). L'applicabilité à un système donné dépend de son usage et de son rôle juridique.
- **NIST AI RMF** : le référentiel AI RMF 1.0 fournit une base de gouvernance, de cartographie, de mesure et de gestion des risques ; la page officielle indique qu'une révision est en cours ([Tabassi, 2023](#)).

La conséquence opérationnelle est claire : toute mise en production requiert une validation séparée par les fonctions risque, conformité, juridique et IT. Les références ci-dessus doivent être relues à chaque changement de périmètre, de modèle, de fournisseur ou de régime

réglementaire.

3.3 Grille d'évaluation et scoring

La grille compare les solutions sans confondre popularité open source et aptitude à un environnement de marché régulé. Chaque critère reçoit une note de 0 à 3 :

- 0 : critère absent ou impossible à vérifier dans les sources publiques ;
- 1 : élément partiel, seulement illustré ou nécessitant un développement important ;
- 2 : capacité documentée et utilisable avec une adaptation maîtrisée ;
- 3 : capacité explicite, testable et directement intégrable dans un workflow contrôlé.

TABLE 3.1. Grille de scoring des solutions agentiques et quantitatives.

Critère	Question d'évaluation	Barème 0-3	Interprétation
Couverture fonctionnelle	Le projet couvre-t-il orchestration, données, backtest, risque, exécution ou reporting ?	0 absent ; 1 partiel ; 2 plusieurs fonctions ; 3 chaîne cohérente	Mesure l'étendue, sans assimiler étendue et maturité.
Reproductibilité	Les calculs et décisions peuvent-ils être rejoués avec les mêmes données et paramètres ?	0 non vérifiable ; 1 exemples ; 2 pipeline documenté ; 3 tests et versionnement	Condition de base pour audit et validation.
Explicabilité	Les sorties relient-elles la justification aux signaux, sources et contraintes ?	0 aucune ; 1 texte libre ; 2 sorties structurées ; 3 preuve liée aux données	Distingue une narration plausible d'une explication vérifiable.
Contrôle du risque	Existe-t-il des limites, validations, stress tests ou garde-fous ?	0 absent ; 1 implicite ; 2 documenté ; 3 bloquant et testé	Critère critique avant toute exécution.
Qualité logicielle	Le dépôt propose-t-il documentation, tests, exemples et structure maintenable ?	0 absent ; 1 incomplet ; 2 présent ; 3 intégré et suivi	Réduit le risque opérationnel.
Intégrabilité	Le projet s'interface-t-il avec Python, bases, API ou moteurs de backtesting ?	0 isolé ; 1 adaptation forte ; 2 interfaces disponibles ; 3 intégration directe	Détermine la faisabilité d'une architecture composée.
Gouvernance	Les rôles, permissions, journaux et validations sont-ils explicitement modélisés ?	0 absent ; 1 déclaratif ; 2 partiel ; 3 contrôlable et auditable	Indispensable dans une institution financière.

Le score maximal est de 21 points. Les notes ci-dessous sont une lecture documentaire provisoire des dépôts retenus ; elles ne constituent ni une certification, ni une validation de production. Elles servent à rendre visibles les arbitrages effectués dans le mémoire.

TABLE 3.2. Scoring documentaire provisoire des dépôts retenus.

Dépôt	Couverture	Reprod.	Explic.	Risque	Qualité	Intégr.	Gouv.	Total
LangGraph	2	3	2	1	3	3	2	16/21
Qlib	3	3	1	1	3	3	1	15/21
Lean	3	3	1	2	3	3	1	16/21
OpenBB	2	2	1	0	3	3	1	12/21
TradingAgents	2	1	2	0	2	2	1	10/21
FinRobot	2	1	2	0	2	2	1	10/21
FinRL	2	2	1	1	2	2	1	11/21
Freqtrade	3	2	1	1	3	3	1	14/21

Le tableau confirme le choix d'une architecture composée. LangGraph obtient son meilleur niveau sur l'orchestration et l'intégrabilité, tandis que Qlib et Lean sont plus solides pour la recherche et le backtesting. Les scores de gouvernance et de contrôle du risque restent faibles ou partiels, ce qui justifie l'ajout de règles métier externes et d'une validation humaine.

3.4 Principes de conception

Ces principes ne sont pas des hypothèses statistiques. Ils fixent les règles de conception qui relient le socle quantitatif, la couche agentique et la gouvernance :

Séparation du calcul et de l'interprétation : les facteurs, rendements, pondérations, coûts et indicateurs de risque sont calculés par des fonctions déterministes. L'agent lit ces sorties, les contrôle et les explique sans les réécrire.

Supervision humaine : une recommandation agentique est un objet de revue. Toute action engageant le portefeuille, et notamment l'envoi d'un ordre, reste soumise à une validation explicite et à des permissions indépendantes.

Explicabilité vérifiable : une justification doit renvoyer aux données, aux versions, aux contraintes et aux règles réellement utilisées. Le texte produit ne remplace pas le journal structuré.

3.5 Méthode de classement des solutions

Chaque projet est classé selon son rôle principal :

Orchestration : organisation des agents, des tâches, de l'état et des outils.

Recherche financière : collecte, résumé et analyse d'informations financières.

Infrastructure quantitative : calcul de signaux, backtesting, environnement de simulation ou moteur d'exécution.

Gouvernance : capacité à tracer, valider, surveiller et expliquer les décisions.

Cette classification évite une erreur fréquente : comparer un framework agentique comme LangGraph à un moteur de backtesting comme Lean. Les deux sont complémentaires. Dans une architecture cible, LangGraph peut piloter le workflow, Qlib calculer des signaux, OpenBB fournir des données, Lean simuler l'exécution, et un agent spécialisé produire un rapport de décision.

3.6 Protocole expérimental

Un prototype quantitatif minimal a été ajouté afin de tester le socle déterministe de l'architecture proposée. Le but n'est pas de démontrer qu'un agent ou une stratégie produit systématiquement de l'alpha, mais de vérifier que les données, les calculs de portefeuille, les coûts et les indicateurs de risque peuvent être rejoués de manière reproductible avant toute intervention d'un agent de synthèse.

Le protocole utilise quatre ETF factoriels américains comme proxies investissables de sleeves de valeur, momentum, qualité et faible volatilité : VLUE, MTUM, QUAL et USMV. Ces ETF ne constituent pas une reconstruction titre par titre des facteurs value, momentum, quality et low volatility : ils servent de portefeuilles observables représentant ces expositions. Le benchmark est SPY. Les cours ajustés sont téléchargés via `yfinance` ([Aroussi, 2026](#)) sur la période allant du 1er janvier 2015 au 31 décembre 2025. Le portefeuille multifactoriel est équilibré et rééquilibré à la fin de chaque mois.

Trois hypothèses de coûts de transaction sont testées : 0, 10 et 30 points de base par unité de turnover. Le taux sans risque est fixé à 0 % pour faciliter la comparaison du ratio de

Sharpe. Les indicateurs calculés sont le rendement annualisé, la volatilité annualisée, le ratio de Sharpe, le maximum drawdown, la valeur finale d'un investissement initial de 100 unités et le turnover.

Pour un mois t , le rendement net du portefeuille est calculé selon :

$$r_t^{\text{net}} = \sum_i w_{i,t-1} r_{i,t} - c\tau_t, \quad \tau_t = \frac{1}{2} \sum_i |w_{i,t} - w_{i,t-1}|,$$

où c désigne le coût unitaire exprimé en fraction et τ_t le turnover au rebalancement. Sur T rendements mensuels, les métriques principales sont :

$$R_{\text{ann}} = \left(\prod_{t=1}^T (1 + r_t) \right)^{12/T} - 1, \quad \sigma_{\text{ann}} = \sqrt{12} \text{sd}(r_t), \quad S = \frac{R_{\text{ann}}}{\sigma_{\text{ann}}}.$$

Le drawdown est obtenu à partir du rapport entre la valeur courante et le maximum historique de la valeur cumulée. Ces formules rendent explicite le traitement des coûts, du turnover et de l'annualisation.

Le déroulement peut être résumé par le pseudo-code suivant :

```
charger les cours ajustés des cinq ETF
verifier les dates, valeurs manquantes et prix non positifs
calculer les rendements mensuels
initialiser les poids a 25 % pour chaque sleeve
a chaque fin de mois :
    mesurer le turnover et appliquer le cout
    calculer rendement, risque, drawdown et valeur finale
exporter period_metrics.csv et quality_report.json
```

Le calcul sépare l'échantillon complet de la période hors échantillon allant de janvier 2021 à décembre 2025. Comme aucun paramètre n'est appris sur les rendements, cette coupure constitue un contrôle de robustesse temporelle et non une validation complète d'un modèle prédictif. Les métriques des deux périodes sont conservées dans `period_metrics.csv`.

Le téléchargement contient 2 766 observations quotidiennes. Le contrôle qualité n'a relevé ni date dupliquée, ni valeur manquante, ni prix non positif. L'écart calendaire maximal

est de quatre jours, aucun gap supérieur à sept jours n'est observé et aucun mouvement quotidien supérieur à 25 % n'est signalé. Les contrôles et leurs limites connues sont archivés dans `data/quality_report.json`. Les cours sont auto-ajustés par la source, mais les corporate actions, le survivorship bias, la liquidité et le slippage nécessitent encore une validation institutionnelle ; les scénarios de 10 et 30 points de base restent des proxys de coûts tout compris.




FIGURE 3.1. Déroulement du protocole expérimental et contrôle hors échantillon.

3.7 Limites de la méthode

Le benchmark proposé constitue une première validation empirique du socle quantitatif, mais pas une évaluation complète d'un système agentique. Une telle évaluation nécessiterait un univers d'actifs, des données historiques propres, un protocole hors échantillon, une modélisation des coûts et des contraintes de liquidité. L'objectif est donc architectural et méthodologique : identifier les briques pertinentes, analyser leur rôle et proposer une architecture explicable.

Une autre limite concerne l'évolution rapide des dépôts GitHub. Les projets agentiques sont actifs, changent fréquemment d'API et peuvent modifier leur licence ou leur stratégie de maintenance. Toute décision d'adoption doit donc inclure une revue technique datée, une analyse de sécurité des dépendances et une validation juridique de la licence.

Chapitre 4

Architecture cible pour un desk multifactoriel agentique

4.1 Principe directeur

L'architecture cible est hybride : les calculs financiers sont exécutés par des composants déterministes, tandis que les agents organisent l'information, interprètent les résultats, vérifient la cohérence et préparent une décision soumise à validation. Cette séparation est la condition pour relier la flexibilité des LLM à des contrôles reproductibles.

Le prototype ne constitue pas une plateforme opérationnelle. Il illustre la manière dont LangGraph peut coordonner des sorties quantitatives déjà calculées, appliquer des contrôles de permission et conserver une trace exploitable. Les mêmes principes pourraient être réalisés avec d'autres frameworks, mais les interfaces et les garde-fous doivent rester explicites.

4.2 Vue d'ensemble de l'architecture

La chaîne complète distingue les données, les calculs, les agents et la gouvernance. Les flèches représentent un passage d'état ; une sortie non conforme revient au composant qui doit la corriger et n'est pas transmise automatiquement à l'étape suivante.




FIGURE 4.1. Architecture cible séparant le socle quantitatif, les agents et la gouvernance.

4.3 Socle quantitatif déterministe

Le socle quantitatif prend en charge les calculs qui exigent exactitude, reproductibilité et validation indépendante : données de marché, facteurs, portefeuilles, risque, coûts et contraintes. Chaque outil reçoit des entrées versionnées et renvoie des valeurs numériques structurées, un horodatage, les paramètres utilisés et les éventuelles erreurs.

Les agents ne calculent pas directement les métriques financières. Ils demandent à des outils déterministes de produire les mesures, puis les lisent, les comparent, les contextualisent et les documentent. Une sortie mal formée, une donnée absente ou une limite franchie doit interrompre le flux. L'agent ne peut pas transformer cette erreur en recommandation positive par une reformulation textuelle.

Le contrat fonctionnel minimal du socle est le suivant :

- entrée : source de données, univers, horizon, paramètres de marché et contraintes de portefeuille ;
- traitement : calcul déterministe, versionné et rejouable ;
- sortie : valeurs numériques structurées, horodatage, paramètres utilisés, hypothèses et éventuelles erreurs ;
- contrôle : conservation des logs, séparation des droits et capacité à refaire le calcul avec les mêmes données.

4.4 Agents proposés

TABLE 4.1. Rôles, permissions et limites des agents proposés.

Agent	Mission	Outils autorisés	Sortie attendue	Interdictions	Conditions d'escalade
Données	Vérifier disponibilité, fraîcheur, provenance et cohérence.	APIs de données, contrôles qualité, logs.	Rapport de qualité et alertes.	Ne pas corriger silencieusement une donnée.	Donnée manquante, périmée ou incohérente.
Facteurs	Lancer les calculs et comparer les distributions.	Moteur déterministe, notebooks validés.	Scores, variations et anomalies.	Ne pas changer la formule ni les paramètres.	Rupture de distribution ou résultat non rejouable.
Actualités	Résumer nouvelles, résultats et événements macro.	OpenBB, flux autorisés, base RAG.	Synthèse sourcée et confiance.	Ne pas modifier les poids ni produire d'ordre.	Sources contradictoires ou absence de source.
Portefeuille	Proposer une allocation sous contraintes.	Optimiseur, mandat et coûts.	Poids cibles et attribution.	Ne pas contourner un rejet risque ou confort.	Allocation infaisable ou contrainte violée.
Risque	Contrôler expositions, volatilité, drawdown et scénarios.	Moteur de risque, limites, stress tests.	Avis accepté, rejeté ou escaladé.	Ne pas relever lui-même une limite.	Limite franchise, modèle absent ou liquidité inconnue.
Conformité	Vérifier restrictions, documentation et séparation des rôles.	Référentiel de règles, listes, audit.	Validation ou blocage motivé.	Ne pas accorder d'exception implicite.	Règle inconnue, conflit ou trace incomplète.
Superviseur	Agréger les avis et préparer la revue humaine.	État complet, règles de délégation, journal.	Note de décision traçable.	Ne pas exécuter ni masquer un désaccord.	Désaccord, confiance faible ou intervention requise.

La séparation des rôles devient un contrôle effectif seulement si elle est inscrite dans les permissions des outils. L'agent actualités peut enrichir le contexte, mais ne doit pas modifier les poids. L'agent portefeuille peut proposer une allocation, mais ne peut pas ignorer un rejet de l'agent risque. Le superviseur doit conserver les avis divergents dans le journal.




FIGURE 4.2. Permissions, escalades et interdictions dans la couche agentique.

4.5 Flux de décision et boucle de rejet

Le flux de décision comporte sept étapes : ingestion, contrôle qualité, calcul factoriel, contextualisation, construction du portefeuille, contrôles indépendants, puis décision supervisée. Le passage à l'étape suivante dépend d'une condition explicite ; une anomalie bloque le graphe ou renvoie l'état vers le composant responsable.

TABLE 4.2. Séquence de décision et conditions de rejet.

Étape	Émetteur	Destinataire	Échange et condition
1	Données	Contrôle qualité	Les données et leur version sont chargées ; une anomalie bloque le flux.
2	Contrôle qualité	Moteur factoriel	Le calcul démarre seulement si les contrôles sont conformes.
3	Moteur factoriel	Optimiseur	Les signaux et paramètres sont transmis sous forme structurée.
4	Optimiseur	Moteur de risque	Les poids proposés sont contrôlés avec les coûts et les contraintes.
5	Moteur de risque	Optimiseur	En cas de rejet, l'état revient à l'optimiseur avec le motif ; aucune allocation n'est validée.
6	Risque et conformité	Superviseur	Les avis, alertes et permissions sont agrégés sans supprimer les désaccords.
7	Superviseur	Humain puis archive	La validation, la modification ou le rejet sont enregistrés dans le journal JSON.




FIGURE 4.3. Séquence de décision avec boucle de rejet par le contrôle risque.

Cette séquence matérialise le *human-in-the-loop*. L'automatisation est adaptée aux étapes reproductibles ; l'autonomie complète est exclue pour les étapes qui engagent le portefeuille ou la conformité.

4.6 Journal de décision explicable

Chaque recommandation doit produire un enregistrement structuré contenant l’horodatage, la version des données et du code, l’univers, les contraintes, les facteurs, les sources, l’allocation proposée, les coûts, les limites de risque, les avis des agents et la décision humaine. Le texte généré est une vue de lecture ; la preuve est le contenu structuré du journal.

L’extrait suivant est issu de la trace du prototype du 30 novembre 2025. Il montre les rendements observés, le rendement net, le turnover, les poids cibles et les permissions effectives.

```
{
  "workflow": "langgraph_deterministic_supervisor",
  "date": "2025-11-30",
  "quality_ok": true,
  "risk_status": "a valider",
  "rebalance": {
    "factor_returns": {
      "Value": 0.024998,
      "Momentum": -0.015616,
      "Quality": 0.009068,
      "Low volatility": 0.023074
    },
    "net_return": 0.010367,
    "turnover": 0.013515,
    "target_weights": {
      "VLUE": 0.25, "MTUM": 0.25,
      "QUAL": 0.25, "USMV": 0.25
    }
  },
  "permissions": {
    "can_change_weights": false,
    "can_send_orders": false,
    "human_validation_required": true
  }
}
```

FIGURE 4.4. Extrait réel du journal JSON produit par le prototype.

Ce format permet de revenir à l’état du système au moment de la recommandation. Il rend également vérifiable le fait que l’agent n’avait ni la permission de modifier les poids, ni celle d’envoyer un ordre.

4.7 Monitoring continu

Le monitoring associe les indicateurs financiers à des métriques spécifiques aux agents. Les seuils ci-dessous sont indicatifs pour le prototype ; ils doivent être calibrés sur des données de production, un budget de latence et une politique de risque validée.

TABLE 4.3. Métriques agentiques, seuils d'alerte et réactions.

Métrique	Seuil indicatif	Réaction	Responsable
Taux de citations valides	< 98 % sur un lot contrôlé	Bloquer la note et demander une nouvelle vérification des sources.	Conformité et superviseur
Échec des appels d'outils	> 5 % sur une fenêtre glissante	Réessayer, passer en mode observation et ouvrir un incident si le taux persiste.	IT et propriétaire du workflow
Désaccord entre agents	> 20 % des décisions	Imposer une revue humaine et conserver les avis divergents.	Superviseur et risque
Intervention humaine	> 30 % des décisions	Analyser la charge, les motifs d'escalade et la qualité des règles.	Superviseur
Temps moyen de réponse	> 30 secondes sur le périmètre cible	Ne pas contourner les contrôles ; réduire le périmètre ou repasser en mode observation.	IT
Coût moyen par décision	Dépassement du budget validé	Limiter les appels, revoir le modèle et suspendre l'usage non essentiel.	Propriétaire du service




FIGURE 4.5. Monitoring agentique et réactions en cas de dépassement de seuil.

Ces métriques complètent le suivi du rendement, de la volatilité, du drawdown, du turnover, des coûts et de l'attribution factorielle. Une dérive financière ou agentique doit pouvoir

déclencher une alerte, un blocage, un retour à une stratégie de référence ou une revue indépendante.

4.8 Exemple de scénario de rééquilibrage

Lors d'un rééquilibrage, l'agent données vérifie les cours et les paramètres. L'agent facteurs calcule les signaux, l'agent actualités contextualise les événements et l'agent portefeuille propose une allocation. L'agent risque contrôle alors les expositions et peut rejeter la proposition si une contrainte est violée. Dans ce cas, l'état revient à l'optimiseur avec le motif du rejet ; l'agent conformité intervient ensuite et le superviseur prépare une note pour la validation humaine.

La valeur de la couche agentique réside dans la coordination, la détection d'anomalies, la contextualisation et la production d'une trace. Elle ne réside pas dans le remplacement des calculs ni dans l'exécution autonome.

Chapitre 5

Discussion et analyse critique

5.1 Apports de l'approche agentique

L'approche agentique apporte une réponse crédible à plusieurs limites des chaînes quantitatives classiques. Une stratégie multifactorielle produit souvent des sorties numériques difficiles à contextualiser : scores, expositions, contraintes actives, turnover et attribution. Les agents peuvent transformer ces sorties en une note compréhensible, relier les mouvements du portefeuille à des événements de marché et signaler les cas où le modèle statistique semble en contradiction avec l'information qualitative.

Le deuxième apport est organisationnel. Une architecture multi-agents reproduit la séparation des responsabilités d'un desk : recherche, risque, conformité, exécution et supervision. Cette séparation rend le système plus auditable qu'un agent monolithique. Elle permet aussi de tester chaque agent séparément : exactitude des synthèses pour l'agent actualités, respect des limites pour l'agent risque, complétude documentaire pour l'agent conformité.

Le troisième apport concerne la mémoire. Des projets comme FinMem montrent qu'un agent peut conserver un historique structuré des événements et de ses propres décisions. Dans un contexte de marché, cette mémoire doit être contrôlée : elle peut aider à détecter les régimes récurrents, mais elle peut aussi renforcer des biais si elle n'est pas validée par des métriques objectives.

5.2 Risques spécifiques

Les risques spécifiques sont reliés à des contrôles, à des responsables et à des décisions observables. Cette présentation évite de traiter une faiblesse agentique comme un simple problème de rédaction.

TABLE 5.1. Risques agentiques, contrôles et responsabilités.

Risque	Exemple	Conséquence	Contrôle	Responsable
Hallucination	Source inexistante ou chiffre mal interprété.	Décision fondée sur une information fausse.	Récupération sourcée, validation des citations, blocage si source invalide.	Conformité
Surapprentissage narratif	Explication convaincante d'un signal non robuste.	Confusion entre récit et preuve financière.	Séparation temporelle, coûts, benchmark et tests de sensibilité.	Quant et risque
Permission excessive	Agent autorisé à modifier les poids ou à appeler l'exécution.	Action non validée et difficile à annuler.	Permissions minimales, outils déterministes et validation humaine.	IT et risque
Dépendance au modèle	Réponse différente après changement de version.	Décision non reproductible ou dérive de comportement.	Versionnement des modèles, prompts, données, outils et sorties.	Propriétaire IA
Désaccord non traité	Agents risque et portefeuille produisent des avis incompatibles.	Consensus artificiel et perte d'un signal d'alerte.	Conservation des avis, escalade et décision humaine explicite.	Superviseur

5.3 Explicabilité : trois niveaux

5.3.1 Explicabilité quantitative

Elle relie la décision aux rendements, aux facteurs, aux pondérations, aux coûts, aux contraintes et aux métriques de risque. Les valeurs doivent provenir des sorties du moteur déterministe et pouvoir être recalculées avec la même version de données.

5.3.2 Explicabilité agentique

Elle décrit les sources consultées, les outils appelés, l'état parcouru, les règles appliquées, le niveau de confiance et les éventuels désaccords entre agents. Une synthèse ne peut être considérée comme fiable que si ses citations et ses entrées structurées sont vérifiables.

5.3.3 Explicabilité de la décision finale

Elle identifie l’avis du superviseur, la règle ou la personne qui a validé, modifié, rejeté ou différé la recommandation. Elle précise également si une permission d’exécution existait. Le journal JSON est donc l’élément de preuve ; la note en langage naturel en est l’interface de lecture.




FIGURE 5.1. Trois niveaux d’explicabilité reliés au journal d’audit.

5.4 Positionnement des solutions GitHub

Les solutions GitHub identifiées peuvent être positionnées sur une échelle de maturité.

Les frameworks comme LangGraph, AutoGen, CrewAI et Semantic Kernel sont matures pour orchestrer des workflows, mais ils ne connaissent pas le métier du trading. Ils sont adaptés à la couche agentique, pas au moteur financier.

Les plateformes comme Qlib, Lean, OpenBB, FinRL et Freqtrade sont utiles pour construire le socle quantitatif. Elles apportent données, backtesting, simulation ou environnement d’apprentissage. Elles ne garantissent pas l’explicabilité agentique, mais elles permettent de rendre les calculs reproductibles.

Les projets comme TradingAgents, FinRobot, FinMem et AI Hedge Fund sont les plus proches de l’intuition multi-agents. Leur valeur est exploratoire : ils montrent comment dé-

couper les rôles et produire des analyses financières. Leur faiblesse est le passage à l'échelle réglementaire : contrôle des données, validation indépendante, limites de risque, sécurité, audit et intégration à une infrastructure institutionnelle.

5.5 Conditions minimales de mise en production

Avant un déploiement réel, un système agentique de trading devrait satisfaire au minimum les conditions suivantes :

- fonctionnement initial en mode observation, sans exécution automatique ;
- jeux de tests sur données historiques et scénarios extrêmes ;
- séparation stricte entre agents de recherche, agents de décision et outils d'exécution ;
- limites de risque codées hors LLM et impossibles à contourner par prompt ;
- registre d'audit complet et horodaté ;
- validation indépendante par risque, conformité et IT ;
- plan de repli en cas d'indisponibilité du modèle ou de dérive des sorties ;
- revue périodique des performances financières et des erreurs agentiques.

La trajectoire raisonnable est donc graduelle : assistant de recherche, assistant de reporting, assistant de revue de risque, puis assistant de recommandation supervisée. Le passage à une autonomie d'exécution ne devrait être envisagé qu'après une longue période de monitoring et seulement pour des stratégies à périmètre limité.

5.6 Résultats du prototype expérimental

Le prototype présenté au chapitre 3 fournit une première mesure du comportement d'une combinaison équipondérée de quatre sleeves factoriels. Les résultats sont comparés à l'ETF SPY sur la période février 2015-décembre 2025, qui correspond aux rendements mensuels calculés à partir des cours ajustés.

TABLE 5.2. Résultats du prototype multifactoriel et du benchmark.

Scénario	Rend. ann.	Vol. ann.	Sharpe	Drawdown	Valeur finale	Turnover mensuel
SPY	13,95 %	14,96 %	0,946	-23,93 %	411,73	-
Multifactoriel, 0 pb	12,11 %	14,17 %	0,876	-23,84 %	345,38	1,26 %
Multifactoriel, 10 pb	12,10 %	14,17 %	0,875	-23,86 %	344,82	1,26 %
Multifactoriel, 30 pb	12,06 %	14,17 %	0,873	-23,88 %	343,69	1,26 %

Sur cette période, le benchmark SPY obtient le rendement annualisé le plus élevé et le meilleur ratio de Sharpe. Le portefeuille multifactoriel présente toutefois une volatilité et un drawdown légèrement inférieurs. Les coûts de transaction modifient peu le résultat dans cette configuration, car le turnover mensuel moyen reste limité.

Une vérification temporelle est également effectuée sur la période hors échantillon 2021-2025. À 10 points de base, le multifactoriel obtient un rendement annualisé de 11,45 %, une volatilité de 14,37

TABLE 5.3. Contrôle hors échantillon sur la période 2021-2025.

Scénario	Rend. ann.	Vol. ann.	Sharpe	Drawdown	Valeur finale	Turnover mensuel
SPY	14,60 %	15,14 %	0,965	-23,93 %	195,39	-
Multifactoriel, 10 pb	11,45 %	14,37 %	0,816	-23,86 %	170,33	1,53 %




FIGURE 5.2. Évolution d'un investissement initial de 100 unités.




FIGURE 5.3. Drawdown du benchmark et des portefeuilles multifactoriels.

Ces résultats ne prouvent donc pas la supériorité financière de la stratégie multifactorielle. Ils montrent plutôt l'intérêt d'un socle quantitatif reproductible auquel un agent peut être relié. L'agent pourrait recevoir ces sorties structurées afin de produire une note de décision, mais il ne doit ni recalculer les métriques ni modifier les pondérations sans règle déterministe et validation humaine.

5.7 Démonstration de la couche agentique

Le module `agent_workflow.py` exécute désormais ce scénario avec LangGraph. Les deux exemples du 30 novembre et du 31 décembre 2025 sont générés à partir des sorties structurées du rééquilibrage, sans nouvel appel de données et sans accès aux ordres. Le premier exemple correspond au 30 novembre 2025 : les rendements de VLUE, MTUM, QUAL et USMV sont respectivement de +2,50 %, -1,56 %, +0,91 % et +2,31 %. Le rendement net du portefeuille est de +1,04 % pour un turnover de 1,35 %. La note conclut que la hausse de VLUE et USMV compense la baisse de MTUM et recommande de conserver les pondérations cibles de 25 %, sous réserve d'une validation humaine.

Le second exemple correspond au 31 décembre 2025 : VLUE progresse de +2,90 %, MTUM de +0,29 %, QUAL de +0,58 % et USMV recule de -0,82 %. Le rendement net du por-

tefeuille atteint +0,74 % pour un turnover de 1,07 %. La note identifie VLUÉ comme principal facteur favorable, signale la contribution négative de USMV et ne propose aucun ajustement exceptionnel.

Ces notes sont comparées aux fichiers de sortie du prototype selon quatre critères : fidélité aux chiffres, complétude, respect des permissions et explicitation des limites. Le résultat est observable sur les deux exécutions ; cette évaluation manuelle constitue une première vérification qualitative et non une mesure statistique de la qualité d'un agent.

TABLE 5.4. Évaluation des deux démonstrations agentiques.

Date	Fidélité aux chiffres	Complétude	Permissions	Limites explicitées	Résultat
30/11/2025	Conforme : rendements, net et turnover cohérents avec le JSON.	Conforme : facteurs favorables et défavorables identifiés.	Conforme : aucun changement de poids ni ordre.	Conforme : validation humaine et limites du moteur signalées.	Conforme
31/12/2025	Conforme : rendements, net et turnover cohérents avec le JSON.	Conforme : VLUÉ et USMV sont correctement contextualisés.	Conforme : aucun changement de poids ni ordre.	Conforme : validation humaine et limites du moteur signalées.	Conforme

5.8 Synthèse

L'approche agentique est pertinente pour un desk multifactoriel si elle est conçue comme une architecture de coordination et d'explicabilité. Elle devient fragile si elle est présentée comme un substitut au modèle quantitatif ou au contrôle humain. Le meilleur compromis consiste à combiner des agents spécialisés avec des moteurs déterministes, des règles non contournables et un journal de décision exploitable par un auditeur.

Chapitre 6

Conclusion

6.1 Réponse à la problématique

Ce mémoire cherchait à déterminer comment utiliser une approche agentique dans un trading multifactoriel sans transformer l'aide à la décision en boîte noire opérationnelle. Les résultats de l'état de l'art et du prototype conduisent à trois réponses complémentaires.

6.1.1 Les tâches pour lesquelles les agents sont utiles

Les agents sont utiles pour traiter l'information hétérogène et préparer une décision : recherche documentaire, veille de marché, synthèse de nouvelles, comparaison de scénarios, contrôle de cohérence, coordination des outils et rédaction d'une note. Leur intérêt est particulièrement visible lorsque plusieurs sources et plusieurs responsabilités doivent être reliées dans un même workflow.

La démonstration LangGraph des 30 novembre et 31 décembre 2025 illustre ce rôle. L'agent lit des rendements et un turnover déjà calculés, les reformule, met en évidence les contributions favorables ou défavorables et rappelle la validation humaine nécessaire. Il apporte donc une valeur d'orchestration et d'interprétation sans devenir le moteur financier.

6.1.2 Les tâches qui doivent rester déterministes

Le calcul des facteurs, des rendements, des pondérations, des coûts, du risque, des contraintes et du drawdown doit rester dans des fonctions versionnées, testables et rejouables. Le moteur de risque doit pouvoir rejeter une allocation indépendamment du texte produit par un agent. Les permissions d'exécution doivent également être codées en dehors du LLM et ne pas dépendre d'une instruction conversationnelle.

Cette séparation ne signifie pas que les composants déterministes sont infaillibles. Elle rend leurs hypothèses visibles, facilite les tests et permet une validation indépendante. Elle évite surtout de confondre la qualité d'une explication avec la robustesse du calcul qu'elle décrit.

6.1.3 Les mécanismes de traçabilité et de contrôle

Un système crédible doit conserver l'état du workflow, les versions des données et du code, les appels d'outils, les sources, les sorties numériques, les avis divergents, les alertes et la décision humaine. Les permissions doivent suivre le principe du moindre privilège. Les conditions d'escalade, les seuils de monitoring et le mode de repli doivent être définis avant tout usage sensible.

Le journal JSON et les métriques agentiques proposées rendent ces contrôles observables : citations valides, échecs d'outils, désaccords, interventions humaines, temps de réponse et coût par décision. La gouvernance ne repose donc pas uniquement sur une consigne générale de prudence ; elle est matérialisée par des états, des règles et des traces.

6.2 Résultats du prototype

Le prototype fournit une validation limitée mais reproductible du socle quantitatif. Sur la période février 2015-décembre 2025, la combinaison équipondérée de VLUE, MTUM, QUAL et USMV, utilisée comme ensemble de proxies factoriels, obtient un rendement annualisé de 12,10 % avec 10 points de base de coûts, contre 13,95 % pour SPY. La volatilité est de 14,17 % contre 14,96 %, tandis que le ratio de Sharpe reste inférieur pour le portefeuille multifactoriel.

Le contrôle hors échantillon sur 2021-2025 confirme la prudence de l'interprétation : le multifactoriel obtient 11,45 % annualisés contre 14,60 % pour SPY, avec un Sharpe de 0,816 contre 0,965. L'expérience ne prouve pas une capacité à générer de l'alpha. Elle montre que les calculs, les coûts, les sorties de risque et la couche agentique peuvent être reliés dans un workflow documenté.

6.3 Limites

Les ETF utilisés sont des proxies investissables et non une reconstruction titre par titre des facteurs. Le protocole ne modélise pas encore de manière institutionnelle le slippage, l'impact de marché, la liquidité, les corporate actions, le survivorship bias ou les contraintes détaillées d'exposition. L'univers et la période restent limités, et l'évaluation agentique repose sur deux démonstrations manuelles.

Le prototype ne comprend pas de validation indépendante en production, de stress tests complets, de comparaison entre plusieurs modèles LLM, ni d'évaluation statistique de la fidélité des réponses sur un grand jeu de cas. Les règles réglementaires, les licences et les dépendances doivent être revérifiées à chaque évolution du périmètre.

6.4 Perspectives

Les prolongements prioritaires sont les suivants :

- reconstruire les facteurs titre par titre sur un univers point-in-time, avec données de publication, coûts de marché et stress tests ;
- évaluer plusieurs modèles et plusieurs prompts sur un jeu de décisions annotées afin de mesurer fidélité, complétude, respect des permissions et capacité d'escalade ;
- brancher un moteur de risque indépendant et tester systématiquement les boucles de rejet ;
- définir un schéma de journal d'audit compatible avec les processus risque, conformité, juridique et IT ;
- mesurer le gain de productivité et les erreurs résiduelles avant tout élargissement de

l'autonomie.

La conclusion générale est qu'une architecture agentique peut rendre le processus d'investissement plus structuré et mieux documenté, à condition de rester hybride. Les agents assistent, expliquent et escaladent ; les moteurs déterministes calculent et bloquent ; l'humain valide les décisions qui engagent le portefeuille.

Bibliographie

- AI4Finance Foundation (2026a). Fingpt : Open-source financial large language models. <https://github.com/AI4Finance-Foundation/FinGPT>. Accessed : August 30, 2026.
- AI4Finance Foundation (2026b). Finrl : Financial reinforcement learning. <https://github.com/AI4Finance-Foundation/FinRL>. Accessed : August 30, 2026.
- AI4Finance Foundation (2026c). Finrl-meta : Market environments and benchmarks for financial reinforcement learning. <https://github.com/AI4Finance-Foundation/FinRL-Meta>. Accessed : August 30, 2026.
- AI4Finance Foundation (2026d). Finrobot : An open-source ai agent platform for financial analysis using llms. <https://github.com/AI4Finance-Foundation/FinRobot>. Accessed : August 30, 2026.
- Aroussi, R. (2026). yfinance : Yahoo finance market data downloader. <https://github.com/ranaroussi/yfinance>. Used for the reproducible prototype ; accessed August 30, 2026.
- CAMEL-AI (2026). Camel : Multi-agent framework. <https://github.com/camel-ai/camel>. Accessed : August 30, 2026.
- Carhart, M. M. (1997). On persistence in mutual fund performance. *The Journal of Finance*, 52(1) :57-82.
- CrewAI Inc. (2026). Crewai : Framework for orchestrating role-playing autonomous ai agents. <https://github.com/crewAIInc/crewAI>. Accessed : August 30, 2026.

- European Parliament and Council of the European Union (2022). Regulation (eu) 2022/2554 on digital operational resilience for the financial sector. <https://eur-lex.europa.eu/eli/reg/2022/2554/oj>. Accessed : August 30, 2026.
- European Parliament and Council of the European Union (2024). Regulation (eu) 2024/1689 laying down harmonised rules on artificial intelligence. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>. Accessed : August 30, 2026.
- European Securities and Markets Authority (2026). Mifid ii, article 17 : Algorithmic trading. <https://www.esma.europa.eu/publications-and-data/interactive-single-rulebook/mifid-ii/article-17-algorithmic-trading>. Accessed : August 30, 2026.
- Fama, E. F. and French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1) :3-56.
- FinMem contributors (2026). Finmem-llm-stocktrading. <https://github.com/pipiku915/FinMem-LLM-StockTrading>. Accessed : August 30, 2026.
- Freqtrade (2026). Freqtrade : Free, open source crypto trading bot. <https://github.com/freqtrade/freqtrade>. Accessed : August 30, 2026.
- LangChain AI (2026). Langgraph : Low-level orchestration framework for building stateful agents. <https://github.com/langchain-ai/langgraph>. Accessed : August 30, 2026.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. <https://arxiv.org/abs/2005.11401>.
- Microsoft (2026a). Autogen : A programming framework for agentic ai. <https://github.com/microsoft/autogen>. Accessed : August 30, 2026.
- Microsoft (2026b). Qlib : Ai-oriented quantitative investment platform. <https://github.com/microsoft/qlib>. Accessed : August 30, 2026.

- Microsoft (2026c). Semantic kernel. <https://github.com/microsoft/semantic-kernel>. Accessed : August 30, 2026.
- OpenAI (2026). Swarm : Educational framework exploring lightweight multi-agent orchestration. <https://github.com/openai/swarm>. Accessed : August 30, 2026.
- OpenBB Finance (2026). Openbb : Financial data platform for analysts, quants and ai agents. <https://github.com/OpenBB-finance/OpenBB>. Accessed : August 30, 2026.
- Patel, V. (2026). Ai hedge fund. <https://github.com/viratatt/ai-hedge-fund>. Accessed : August 30, 2026.
- QuantConnect (2026). Lean algorithmic trading engine. <https://github.com/QuantConnect/Lean>. Accessed : August 30, 2026.
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., and Scialom, T. (2023). Toolformer : Language models can teach themselves to use tools. <https://arxiv.org/abs/2302.04761>.
- Shinn, N., Cassano, F., Berman, E., Gopinath, A., Narasimhan, K., and Yao, S. (2023). Reflexion : Language agents with verbal reinforcement learning. <https://arxiv.org/abs/2303.11366>.
- Tabassi, E. (2023). Artificial intelligence risk management framework (ai rmf 1.0). Technical Report NIST AI 100-1, National Institute of Standards and Technology. Accessed : August 30, 2026 ; official page indicates that AI RMF 1.0 is under revision.
- Tauric Research (2026). Tradingagents : Multi-agents llm financial trading framework. <https://github.com/TauricResearch/TradingAgents>. Accessed : August 30, 2026.
- Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., and Wang, C. (2023). Autogen : Enabling next-gen llm applications via multi-agent conversation. <https://arxiv.org/abs/2308.08155>.

- Yang, H., Liu, X.-Y., and Wang, C. D. (2023). Fingpt : Open-source financial large language models. <https://arxiv.org/abs/2306.06031>.
- Yang, H., Zhang, B., She, Y., Liao, X., and Zhang, X. (2026). Finrl-x : An ai-native modular infrastructure for quantitative trading. <https://arxiv.org/abs/2603.21330>.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. (2023). React : Synergizing reasoning and acting in language models. <https://arxiv.org/abs/2210.03629>.
- Yu, Y., Li, H., Chen, Z., Jiang, Y., Li, Y., Zhang, D., Liu, R., Suchow, J. W., and Khashanah, K. (2023). Finmem : A performance-enhanced llm trading agent with layered memory and character design. <https://arxiv.org/abs/2311.13743>.

Annexes

Annexe I

Matrice des solutions GitHub

I.1 Solutions recommandées pour l'étude comparative

Cette annexe synthétise les dépôts les plus directement exploitables pour transformer l'état de l'art en cartographie exploitable. Les URLs et licences doivent être revérifiées avant tout usage institutionnel.

TABLE I.1. Matrice de sélection des dépôts GitHub.

Dépôt	Rôle	Usage conseillé	Précaution
LangGraph	Orchestration	Construire le graphe d'étapes : ingestion, calcul, analyse, risque, conformité, supervision.	Versionner les états et imposer des sorties structurées.
AutoGen	Collaboration multi-agents	Prototyper des conversations entre agents analystes et contrôleurs.	Encadrer strictement les permissions d'outils.
CrewAI	Agents par rôles	Démontrer rapidement un workflow de recherche financière.	Ajouter logs, contrôles et tests avant usage sérieux.
Semantic Kernel	Intégration entreprise	Connecter agents, fonctions et plugins dans un environnement Microsoft.	Ne fournit pas de modèle financier prêt à l'emploi.
Qlib	Recherche quantitative	Calculer signaux, entraîner modèles, back-tester des stratégies.	Adapter données, coûts et contraintes au mandat réel.
Lean	Backtesting et exécution	Simuler et exécuter des stratégies multi-actifs.	Garder l'exécution sous règles déterministes.
OpenBB	Données et recherche	Alimenter un agent de veille et de synthèse financière.	Vérifier les licences des fournisseurs de données.
FinRL / FinRL-Meta	Agents RL financiers	Comparer LLM agents et RL sur environnements de marché.	Risque fort de surapprentissage.
TradingAgents	Multi-agents trading	Inspirer l'équipe d'agents : analystes, trader, risque.	Prototype de recherche, non suffisant pour production régulée.
FinRobot	Agents financiers LLM	Automatiser recherche actions et valorisation.	Compléter par un moteur quantitatif et des contrôles.
FinMem	Mémoire agentique	Étudier l'impact d'une mémoire structurée sur les décisions.	Valider empiriquement la robustesse hors échantillon.
AI Hedge Fund	Démonstrateur pédagogique	Montrer la division des rôles dans un fonds simulé.	Preuve de concept, pas outil de trading réel.

I.2 Due diligence des dépôts au 30 août 2026

Les informations ci-dessous ont été relevées sur les dépôts publics et l'API GitHub le 30 août 2026. La date de dernier push renseigne l'activité observée, mais ne garantit ni la maintenance ni l'aptitude à un usage institutionnel. Le propriétaire public est indiqué ; le nombre de mainteneurs actifs n'est pas assimilé au nombre de contributeurs.

TABLE I.2. Grille de due diligence des briques sélectionnées.

Dépôt	Licence	Dernier push	Docs et tests	Sécurité	Avis provisoire
LangGraph (LangChain AI, 2026)	MIT	30/08/2026	README, docs ; tests à inspecter	Politique présente	Orchestration active ; audit dépendances.
Qlib (Microsoft, 2026b)	MIT	23/07/2026	docs, tests	SECURITY.md	Brique quantitative documentée.
Lean (QuantConnect, 2026)	Apache-2.0	28/08/2026	README, Tests	À vérifier	Moteur actif ; audit des données.
OpenBB (OpenBB Finance, 2026)	AGPLv3*	30/07/2026	README, pytest.ini	SECURITY.md	Licence à valider juridiquement.
TradingAgents (Tauric Research, 2026)	Apache-2.0	30/08/2026	README, tests	À vérifier	Prototype multi-agents.
FinRobot (AI4Finance Foundation, 2026d)	Apache-2.0	23/08/2026	README, test_module.py	À vérifier	Démonstrateur financier.
FinRL (AI4Finance Foundation, 2026b)	MIT	13/07/2026	docs, unit_tests	À vérifier	RL ; surapprentissage à contrôler.
Freqtrade (Freqtrade, 2026)	GPL-3.0	27/08/2026	docs, tests	À vérifier	Bot crypto ; périmètre différent.

* Le README OpenBB déclare AGPLv3, tandis que l'API GitHub renvoie NOASSERTION ; une vérification juridique est donc obligatoire. Le fichier structuré complet est archivé dans `github_due_diligence.json`.

I.3 Statut d'utilisation dans le mémoire

La due diligence est complétée par un statut d'utilisation. Cette distinction indique si une brique a été exécutée dans le prototype, utilisée comme référence pour la conception ou seulement étudiée dans la cartographie.

TABLE I.3. Statut des solutions dans le travail réalisé.

Dépôt	Statut	Rôle dans le travail
LangGraph	Utilisé dans le prototype	Workflow déterministe de lecture des sorties quantitatives, génération des notes et contrôle des permissions.
Qlib	Référence étudiée	Comparaison pour la recherche quantitative et le backtesting ; non branché au calcul final.
Lean	Référence comparative	Exemple de moteur multi-actifs pour une évolution future du socle.
OpenBB	Référence étudiée	Brique étudiée pour la veille et la provenance des données ; non branchée au prototype.
TradingAgents	Étudié, non exécuté	Référence pour la séparation des rôles dans une architecture multi-agents financière.
FinRobot	Étudié, non exécuté	Référence pour les assistants de recherche et d'analyse financière.
FinRL	Étudié, non retenu	Solution RL documentée, hors périmètre du prototype ETF équilibré.
Freqtrade	Étudié, hors périmètre principal	Brique crypto utile pour comparaison, mais non adaptée au protocole retenu.

I.4 Combinaison minimale

Pour une étude de master réaliste, la combinaison suivante est suffisante :

- LangGraph pour imposer un workflow auditable ;
- Qlib ou Lean pour calculer et backtester les signaux ;
- OpenBB pour alimenter la veille et les données financières ;
- un agent de synthèse pour produire la note de décision ;
- un registre JSON ou base SQL pour stocker chaque appel d'outil, donnée et validation.

Cette combinaison évite de dépendre d'un seul dépôt. Elle permet aussi de remplacer progressivement les composants : un moteur de risque interne peut remplacer une bibliothèque open source, un modèle LLM privé peut remplacer un modèle externe, et les règles de conformité peuvent être intégrées sous forme de fonctions déterministes.

Annexe II

Checklist de gouvernance d'un agent de trading

II.1 Avant expérimentation

1. Définir le mandat : univers, instruments, horizon, contraintes, benchmark et limites.
2. Identifier les données autorisées et leurs fournisseurs.
3. Versionner le code, les données, les prompts, les modèles et les paramètres.
4. Définir les rôles agents et leurs permissions d'outils.
5. Interdire l'accès direct à l'exécution pour les agents de recherche.
6. Préparer un jeu de tests historiques et des scénarios de stress.

II.2 Pendant le backtesting

1. Séparer entraînement, validation et test hors échantillon.
2. Intégrer coûts, slippage, contraintes de liquidité et turnover.
3. Comparer la stratégie à des benchmarks simples.
4. Journaliser chaque recommandation produite par les agents.
5. Vérifier les sources citées par les agents.

6. Mesurer les erreurs agentiques : hallucinations, appels d'outils échoués, contradictions, refus ou sorties incomplètes.

II.3 Avant passage en observation

1. Faire valider le modèle par une fonction indépendante.
2. Définir des seuils d'alerte : drawdown, volatilité, exposition, concentration, erreurs de données.
3. Tester le plan de repli en cas d'indisponibilité du LLM ou des données.
4. Vérifier la conformité des licences open source et des fournisseurs de données.
5. Mettre en place une revue périodique des logs et des décisions.

II.4 Avant toute exécution réelle

1. Exiger une validation humaine explicite.
2. Imposer des limites de risque codées hors LLM.
3. Bloquer automatiquement tout ordre hors mandat ou hors limite.
4. Conserver une piste d'audit complète et exportable.
5. Documenter les incidents, corrections et changements de modèle.