



CONSERVATOIRE NATIONAL DES ARTS ET MÉTIERS

Master Finance de marché

**L'approche agentique dans un contexte de trading
multifactoriel**

Synthèse LLM et allocation de portefeuille sous contraintes

Nom et prénom : SANOU Abou Dramane

Encadrant : Bertrand DJEMBISSI

Rapport d'étude présenté dans le cadre du Master Finance de marché

Paris, septembre 2026

Résumé

Ce mémoire étudie deux usages d'un LLM en trading multifactoriel : restituer des résultats et proposer une allocation simulée sous contraintes. Le prototype initial associe un backtest Python, LangGraph et une synthèse DeepSeek. Dans l'extension, Python valide les poids proposés et calcule le portefeuille. Aucun outil d'ordre réel n'est accessible.

Quatre ETF représentent les expositions value, momentum, quality et low volatility : VLUE, MTUM, QUAL et USMV. Sur février 2015–décembre 2025, leur allocation équi-pondérée à 10 points de base atteint 12,02 % de rendement annualisé, contre 13,84 % pour SPY. Le contrôle temporel sur 2021–2025 conserve ce classement.

L'évaluation de la synthèse comprend 12 cas, dont 11 répétés trois fois et un cas qualité bloqué. Les 33 réponses passent les contrôles automatisés. Toutefois, trois altérations construites sont également acceptées : un coût nul, une citation inexistante et une recommandation contradictoire. La conformité mesurée ne garantit donc pas la fiabilité générale des notes.

L'extension d'allocation couvre mai 2021–décembre 2025 : 22 des 56 propositions sont exécutées et 34 rejetées, surtout pour dépassement du turnover. Pour 100 unités initiales, DeepSeek termine à 148,39, contre 153,55 pour l'équipondération et 152,26 pour l'inverse volatilité, après frais de transaction. Le replay reproduit ces résultats. Cette expérience rétrospective, exposée au biais de préentraînement et hors coûts API et humains, ne démontre pas d'avantage financier de l'agent.

Mots-clés : agents intelligents, trading multifactoriel, LLM, explicabilité, gouvernance, back-testing, LangGraph.

Abstract

This report examines two uses of an LLM in multifactor trading : summarizing results and proposing constrained allocations in simulation. The initial prototype combines a Python backtest, LangGraph and a DeepSeek summary. In the extension, Python validates proposed weights and computes portfolio values. No live order tool is available.

Four ETFs represent value, momentum, quality and low volatility : VLU, MTUM, QUAL and USMV. Over February 2015–December 2025, their equal-weighted portfolio with 10-basis-point transaction costs achieves a 12.02% annualized return, versus 13.84% for SPY. A temporal check over 2021–2025 preserves this ranking.

The summary evaluation covers 12 cases, including 11 repeated three times and one blocked data-quality case. All 33 responses pass automated checks. However, three constructed alterations also pass : a zero cost, a nonexistent citation and a contradictory recommendation. Measured compliance therefore does not guarantee general reliability.

The allocation extension covers May 2021–December 2025 : 22 of 56 proposals are executed and 34 rejected, mainly for excessive turnover. Starting from 100 units, DeepSeek ends at 148.39, versus 153.55 for equal weighting and 152.26 for inverse volatility, after transaction costs. Archived replay reproduces these results. This retrospective experiment is exposed to pretraining look-ahead bias and excludes API and human costs ; it does not establish a financial advantage for the agent.

Keywords : intelligent agents, multifactor trading, LLM, explainability, governance, backtesting, LangGraph.

Remerciements

Je remercie mon encadrant, Bertrand DJEMBISSI, pour son accompagnement et ses orientations dans la préparation de ce rapport d'étude. Je remercie également l'équipe pédagogique du CNAM pour le cadre de formation fourni au sein du Master Finance de marché.

Déclaration relative à l'utilisation de l'intelligence artificielle

Dans le cadre de la préparation de ce rapport, j'ai utilisé des outils d'intelligence artificielle générative comme assistants de rédaction, de programmation et de vérification. Ils m'ont notamment aidé à corriger des fautes d'orthographe et de grammaire, à améliorer certaines formulations, à repérer des incohérences de notation et à vérifier la cohérence apparente de formules, de pseudo-codes et de portions de code. Cette assistance a également été mobilisée pour développer l'extension d'allocation, préparer ses tests, exécuter les simulations et rédiger leur analyse. Les contrôles automatisés et le replay sont documentés à partir du code, des équations et des archives ; ils ne valent pas validation indépendante de toutes les hypothèses financières. L'intelligence artificielle n'a donc pas été considérée comme une source autonome de résultats : les choix méthodologiques, l'analyse, l'interprétation et la validation finale présentés dans ce mémoire relèvent de ma responsabilité.

Table des matières

	Page
Résumé	i
Abstract	ii
Remerciements	iii
Déclaration relative à l'utilisation de l'intelligence artificielle	iv
Liste des figures	vii
Liste des tableaux	viii
Glossaire	ix
1 Introduction et problématique	1
1.1 Contexte général	1
1.2 Problématique	2
1.3 Objectifs du rapport	2
1.4 Périmètre	3
1.5 Organisation du rapport	3
2 État de l'art et choix des composants	4
2.1 Définir l'approche agentique	4
2.2 Du besoin du prototype au choix des outils	5
2.3 Socle quantitatif et accès aux données	5
2.4 Projets financiers et enseignements retenus	7
2.5 Statut des briques et portée de la revue	7
3 Méthodologie d'analyse	9
3.1 Démarche documentaire	9
3.2 Revue réglementaire arrêtée au 30 août 2026	10
3.3 Grille d'évaluation et scoring	10

3.4	Principes de conception	11
3.5	Protocole expérimental initial	12
3.6	Protocole d'évaluation de la couche LLM	14
3.7	Extension : décisions d'allocation et PnL simulé	16
3.8	Limites de la méthode	20
4	Architecture proposée et composants exécutés	21
4.1	Répartition des responsabilités	21
4.2	Rôles proposés et périmètre réalisé	22
4.3	Journal de décision et explicabilité	23
4.4	Allocation simulée et suivi des incidents	24
5	Résultats expérimentaux et discussion	25
5.1	Résultats du prototype expérimental initial	25
5.2	Démonstration de la couche agentique	27
5.3	Évaluation automatisée de la couche LLM	28
5.4	Comparaison d'une note déterministe et d'une synthèse LLM	30
5.5	Contre-exemples construits pour éprouver le validateur	32
5.6	Résultats de l'allocation proposée par DeepSeek	33
5.7	Enseignements et conditions d'utilisation	40
6	Conclusion	42
6.1	Ce que je retiens du prototype	42
6.2	Limites de portée	43
6.3	Deux suites prioritaires	43
	Bibliographie	44
I	Due diligence des solutions retenues	48
II	Reproduction de l'expérience d'allocation	49
II.1	Fichiers et vérifications	49
II.2	Commandes de reproduction sans appel API	50

Liste des figures

	Page
3.1 Déroulement du protocole expérimental et contrôle hors échantillon.	14
4.1 Architecture cible séparant le socle quantitatif, les agents et la gouvernance. .	21
4.2 Extrait réel du journal JSON produit par le prototype.	23
5.1 Évolution d'un investissement initial de 100 unités.	26
5.2 Drawdown du benchmark et des portefeuilles multifactoriels.	27
5.3 Capital et drawdown des trois politiques d'allocation, de mai 2021 à décembre 2025. Frais de 10 pb par unité de turnover; valeurs quotidiennes.	35

Liste des tableaux

	Page
2.1 Frameworks agentiques généralistes disponibles sur GitHub.	5
2.2 Briques quantitatives GitHub utiles pour une étude multifactorielle.	6
2.3 Solutions GitHub orientées agents financiers.	7
3.1 Scoring documentaire provisoire des dépôts retenus.	11
4.1 Rôles, permissions et limites des agents proposés.	22
5.1 Résultats du prototype multifactoriel et du benchmark.	25
5.2 Contrôle hors échantillon sur la période 2021-2025.	26
5.3 Évaluation des deux démonstrations agentiques.	28
5.4 Résultats selon les contrôles automatisés du protocole LLM.	29
5.5 Extraits des deux restitutions du 31 décembre 2025.	31
5.6 Résultat du validateur sur trois altérations et deux témoins.	32
5.7 Performance de l'expérience d'allocation, mai 2021–décembre 2025.	34
5.8 Rendements nets par année de l'expérience d'allocation.	35
5.9 Motifs de rejet des propositions DeepSeek.	36
5.10 Turnover exécuté et frais déduits des portefeuilles, capital initial 100.	37
5.11 Ressources rapportées par l'API pendant la collecte d'allocation.	37
5.12 Risques agentiques, contrôles et responsabilités.	40
I.1 Grille de due diligence des briques sélectionnées.	48

Glossaire

API interface de programmation applicative.

DOI Digital Object Identifier.

DORA Digital Operational Resilience Act.

ES expected shortfall.

ETF fonds indiciel coté.

HFT trading haute fréquence.

HITL human-in-the-loop.

IA intelligence artificielle.

IT Information Technology.

JSON JavaScript Object Notation.

LLM grand modèle de langage.

MAR Market Abuse Regulation.

MiFID II Markets in Financial Instruments Directive II.

NIST National Institute of Standards and Technology.

PnL profit and loss.

RAG génération augmentée par récupération.

RL apprentissage par renforcement.

RMF Risk Management Framework.

SDK Software Development Kit.

SQL Structured Query Language.

UE Union européenne.

VaR valeur en risque.

Chapitre 1

Introduction et problématique

1.1 Contexte général

Le trading multifactoriel combine plusieurs expositions pour construire un portefeuille. Les modèles de marché, taille et valeur de [Fama et French \(1993\)](#), puis l'introduction du momentum par [Carhart \(1997\)](#), fournissent des repères pour cette démarche. Pour mon étude, j'ai retenu quatre expositions – value, momentum, quality et low volatility – représentées par des ETF. Je voulais partir de portefeuilles observables et consacrer l'expérience au rôle du LLM, plutôt qu'à la reconstruction des facteurs titre par titre.

À partir de ce socle, j'ai cherché à préciser ce que je pouvais confier à un modèle de langage. Les travaux sur ReAct, Toolformer et AutoGen décrivent différentes façons d'associer un LLM à des outils ou à d'autres agents ([Yao et al., 2023](#) ; [Schick et al., 2023](#) ; [Wu et al., 2023](#)). Dans la première expérience, j'ai limité son rôle à la préparation d'une note à partir des sorties du backtest. Une extension évalue ensuite ses propositions de poids ; les contrôles, les rendements et les coûts restent calculés par Python.

J'ai choisi ce périmètre afin de comparer deux restitutions construites à partir des mêmes résultats quantitatifs : une note déterministe et une synthèse DeepSeek. Mon objectif était de suivre les valeurs reprises par le modèle et de repérer les erreurs que les contrôles laissent passer. J'ai ensuite étendu la comparaison au PnL d'un portefeuille issu de ses propositions, face à deux règles simples.

1.2 Problématique

Ma question de travail est la suivante : comment intégrer un LLM à une chaîne multifactorielle tout en gardant la possibilité de vérifier ses chiffres, ses sources et les décisions qui en découlent ? La synthèse fournit un premier cas de contrôle ; l'allocation simulée engage ensuite les poids du portefeuille et leur effet sur le PnL.

Dans mon prototype, j'examine les valeurs du JSON, les champs cités et la recommandation rédigée. Conserver les bons chiffres n'empêche pas une réponse d'omettre une alerte ou de formuler un avis incompatible avec les permissions. J'évalue donc aussi le validateur, en recherchant les erreurs qu'il accepte.

La revue de MiFID II, de DORA et des cadres NIST et AI Act éclaire les questions de contrôle et de documentation abordées dans ce mémoire ([European Securities and Markets Authority, 2026](#) ; [European Parliament and Council of the European Union, 2022](#) ; [Tabassi, 2023](#) ; [European Parliament and Council of the European Union, 2024](#)). Elle est détaillée au chapitre 3. J'en ai retenu une séparation des responsabilités : le LLM prépare la synthèse ou propose des poids ; le code conserve les calculs et les contrôles avant toute transaction simulée. Le modèle de synthèse n'a pas accès à la modification des poids.

1.3 Objectifs du rapport

J'ai organisé ce rapport autour de trois objectifs :

1. décrire un état de l'art ciblé des briques d'orchestration et de contrôle utiles à ce cas d'usage ;
2. construire un socle ETF déterministe, reproductible et suffisamment simple pour isoler le rôle de la couche agentique ;
3. évaluer les sorties DeepSeek : conformité d'une synthèse, puis admissibilité et performance de propositions d'allocation simulées.

J'ai ainsi construit un cas d'étude dont les sorties peuvent être réexaminées : backtest ETF, notes, propositions d'allocation, rejets et coûts. L'évaluation porte sur ces artefacts ; le gain de compréhension ou de temps pour un analyste demanderait une étude auprès d'utilisateurs.

1.4 Périmètre

Le périmètre empirique est limité à quatre ETF factoriels américains et à SPY. Les ETF servent de proxies investissables des expositions value, momentum, quality et low volatility ; les facteurs ne sont pas reconstruits titre par titre. Les futures, les crypto-actifs et les univers d'actions individuelles sont évoqués dans l'état de l'art, mais ne sont pas expérimentés.

J'ai limité le travail à une démonstration expérimentale de la séparation entre calcul, interprétation et contrôle des sorties du LLM. L'objectif n'est pas de démontrer un alpha, mais d'évaluer cette organisation sur un cas reproductible. Aucun ordre réel n'est envoyé.

L'analyse distingue deux niveaux :

Socle quantitatif déterministe : données, rendements, portefeuille, coûts, risque et diagnostics.

Orchestration et gouvernance LLM : workflow, contrat JSON, permissions, rejet et journalisation.

1.5 Organisation du rapport

La revue des solutions et la méthodologie expliquent les choix qui précèdent l'architecture. Le chapitre 5 rassemble les résultats, depuis la comparaison des notes jusqu'au PnL d'allocation, avec leurs coûts et leurs biais. Je termine par les enseignements que j'en retiens et deux suites prioritaires.

Chapitre 2

État de l’art et choix des composants

2.1 Définir l’approche agentique

Dans ce mémoire, le terme « agentique » désigne l’organisation de tâches autour d’un état partagé, d’outils et de règles de passage entre étapes. Le prototype initial en retient une forme limitée : LangGraph coordonne les contrôles et les traitements déterministes, puis peut déclencher une synthèse DeepSeek. Il ne s’agit pas d’une équipe autonome d’agents financiers.

J’ai retenu de ReAct et de Toolformer l’usage d’outils externes pour fournir au modèle les résultats dont il a besoin ([Yao et al., 2023](#) ; [Schick et al., 2023](#)). Dans mon cas d’usage, les rendements, les coûts et les autres valeurs financières sont calculés en amont, puis transmis au modèle. Le RAG pourrait compléter cette architecture pour traiter des documents ou des actualités financières ([Lewis et al., 2020](#)), mais il n’est pas utilisé dans l’expérience.

Reflexion et AutoGen apportent des pistes pour l’architecture cible, avec le retour critique ou les échanges entre agents ([Shinn et al., 2023](#) ; [Wu et al., 2023](#)). Ces mécanismes dépassent le besoin de l’expérience initiale de synthèse : le LLM y restitue un état quantitatif déjà produit. Il ne calcule pas le signal, dont la robustesse doit être évaluée séparément de la qualité de la synthèse.

2.2 Du besoin du prototype au choix des outils

La comparaison de LangGraph et de Lean m’a aidé à séparer deux besoins : organiser les étapes d’un workflow et simuler un portefeuille ([LangChain AI, 2026](#) ; [QuantConnect, 2026](#)). J’ai conservé un moteur Python pour les calculs de quatre ETF, puis LangGraph pour suivre l’état et bloquer la synthèse si le contrôle qualité échoue. Les autres frameworks ont été comparés sur documents, sans essai d’exécution permettant de les classer en performance.

Le tableau 2.1 situe les six frameworks examinés. Le choix de LangGraph repose sur les transitions et le suivi de l’état mobilisés dans mon prototype ; les calculs et les règles métier sont des fonctions séparées.

TABLE 2.1. Frameworks agentiques généralistes disponibles sur GitHub.

Projet GitHub	Positionnement	Intérêt pour un desk multifactoriel	Limites principales
LangGraph (LangChain AI, 2026)	Workflows d’agents sous forme de graphes, avec état persistant et contrôle fin des transitions.	Adapté aux processus audités : ingestion, calcul de facteurs, revue de risque, validation, journalisation.	Nécessite de développer les outils quantitatifs et les contrôles métier autour du graphe.
AutoGen (Microsoft, 2026a)	Conversations multi-agents et orchestration d’équipes d’agents.	Utile pour comparer des rôles de recherche, analyste, contrôleur de risque et superviseur.	Les conversations libres doivent être fortement contraintes pour un usage régulé.
CrewAI (CrewAI Inc., 2026)	Agents orientés rôles, tâches et processus.	Simple pour construire une équipe d’agents de recherche de marché et de reporting.	Moins adapté seul aux workflows critiques nécessitant des états vérifiables et des garde-fous stricts.
Semantic Kernel (Microsoft, 2026c)	SDK Microsoft pour connecter modèles, plugins, fonctions et mémoire.	Intéressant dans un environnement d’entreprise déjà Microsoft, avec intégration possible à des services internes.	L’architecture de trading reste à construire ; le framework ne fournit pas de modèle financier.
CAMEL (CAMEL-AI, 2026)	Environnements et méthodes pour sociétés multi-agents.	Pertinent pour expérimenter des interactions entre analystes spécialisés.	Plus orienté recherche agentique que production financière.
OpenAI Swarm (OpenAI, 2026)	Exemple éducatif de routage entre agents.	Montre clairement la logique de transfert entre rôles.	Projet expérimental, insuffisant pour une architecture de production.

2.3 Socle quantitatif et accès aux données

Une recherche sur actions individuelles demanderait de définir l’univers, préparer les données, calculer les signaux et construire le portefeuille sous contraintes. J’ai réduit ce travail à VLUE, MTUM, QUAL et USMV, initialement équipondérés et rééquilibrés chaque mois. Les ETF représentent les expositions ; le prototype ne reconstruit pas les facteurs titre par titre.

L’extension d’allocation conserve cet univers et compare les propositions DeepSeek à deux règles simples.

TABLE 2.2. Briques quantitatives GitHub utiles pour une étude multifactorielle.

Projet GitHub	Fonction principale	Apport dans l’architecture cible	Point d’attention
Qlib (Microsoft, 2026b)	Plateforme Microsoft orientée recherche quantitative, données, modèles et backtesting.	Bon socle pour tester des facteurs, pipelines de données et modèles prédictifs.	Adaptation nécessaire aux données internes et aux contraintes de portefeuille réelles.
FinRL (AI4Finance Foundation, 2026b) et FinRL-Meta (AI4Finance Foundation, 2026c)	Apprentissage par renforcement pour trading automatisé et environnements de marché.	Utile pour comparer une approche agentique LLM avec des agents RL plus classiques.	Le RL financier souffre fortement du surapprentissage et des coûts de transaction mal modélisés.
FinRL-X (Yang et al., 2026)	Infrastructure modulaire récente pour trading quantitatif natif IA.	Référence pour étudier l’intégration des briques de trading dans une infrastructure modulaire.	Projet récent : maturité opérationnelle à vérifier avant usage critique.
QuantConnect Lean (QuantConnect, 2026)	Moteur open source de backtesting et trading algorithmique multi-actifs.	Brique robuste pour simuler et exécuter des stratégies dans un cadre contrôlé.	L’agent doit rester au-dessus du moteur, sans contourner les règles d’exécution.
OpenBB (OpenBB Finance, 2026)	Plateforme ouverte d’accès aux données et analyses financières.	Source pratique pour créer un agent de recherche et de veille.	La qualité dépend des fournisseurs de données configurés et de leurs licences.
Freqtrade (Freqtrade, 2026)	Bot de trading crypto avec backtesting et hyperoptimisation.	Utile pour une étude sur crypto-actifs, où l’accès aux données et échanges est simple.	Domaine crypto moins représentatif des contraintes actions institutionnelles.

Qlib aurait répondu à un besoin de comparaison de modèles prédictifs ou de pipelines de facteurs. Mon expérience n’apprend pas de modèle et part de quatre ETF : j’ai conservé un moteur Python plus simple. Lean reste une référence pour une simulation multi-actifs plus complète. OpenBB a surtout été étudié pour l’agent de veille proposé ; le backtest disposait déjà de son historique. Une intégration d’actualités demanderait de documenter leur provenance, leur licence et leur disponibilité à la date de décision.

2.4 Projets financiers et enseignements retenus

TABLE 2.3. Solutions GitHub orientées agents financiers.

Projet GitHub	Principe	Ce qu’il apporte au sujet	Limite pour un desk régulé
TradingAgents (Tauric Research, 2026)	Framework multi-agents imitant une société de trading avec analystes spécialisés, trader et gestion du risque.	C’est l’un des dépôts les plus proches de l’idée d’équipe multi-agents appliquée au trading.	À analyser comme démonstrateur de recherche ; il faut ajouter validation des données, limites de risque, audit et contrôle humain.
FinRobot (AI4Finance Foundation, 2026d)	Plateforme d’agents LLM pour applications financières, notamment recherche actions, analyse et valorisation.	Automatisation de tâches d’analyse financière et de rédaction de synthèses structurées.	Plus orienté analyse et reporting que génération robuste d’ordres multifactoriels.
FinMem (Yu et al., 2023 ; FinMem contributors, 2026)	Agent de trading fondé sur mémoire stratifiée et profils de décision.	Montre l’intérêt de la mémoire long terme pour contextualiser les décisions de trading.	Les performances expérimentales ne suffisent pas à prouver une robustesse exploitable en production.
AI Hedge Fund (Patel, 2026)	Démonstrateur open source d’un fonds simulé composé d’agents d’investissement.	Le dépôt illustre une répartition des tâches entre agents d’analyse et agent de décision.	Le dépôt se présente comme preuve de concept, pas comme outil de trading réel.
FinGPT (Yang et al., 2023 ; AI4Finance Foundation, 2026a)	Écosystème de modèles de langage financiers open source.	Modèles financiers à intégrer ou adapter pour des tâches d’analyse spécialisées.	Un modèle financier n’est pas une architecture de décision ; il faut ajouter outils, gouvernance et backtesting.

TradingAgents et FinRobot ont nourri deux aspects du projet : la séparation des rôles d’analyse et de risque, puis les tâches de reporting proches de la note étudiée. FinMem soulève la question des synthèses passées : les conserver pourrait apporter du contexte, mais aussi transmettre leurs erreurs aux décisions suivantes. Cette mémoire reste hors du prototype. Aucun des cinq projets financiers n’a été exécuté ; leurs performances ne sont donc pas comparées à celles du backtest.

2.5 Statut des briques et portée de la revue

LangGraph est utilisé dans le workflow de restitution. Qlib, Lean et OpenBB sont des références étudiées, sans participation aux calculs finaux. TradingAgents et FinRobot ont inspiré les rôles proposés ; FinRL et Freqtrade relèvent d’autres périmètres expérimentaux. Pour

examiner les dépôts, j’ai regardé l’état, les transitions, les permissions, la persistance, la documentation et les tests. La due diligence datée des huit dépôts retenus figure en annexe [I](#).

La revue a conduit à un cas que je pouvais vérifier à partir des artefacts produits : confronter une réponse DeepSeek aux chiffres sources et à une note déterministe. L’extension mesure ensuite les conséquences de poids proposés sur le PnL. Les interactions libres entre agents et la mémoire ne font pas partie de ces expériences.

Les articles scientifiques étayent les concepts et les résultats ; les textes officiels éclairent la gouvernance. Les prépublications sont signalées comme telles. Les dépôts et documentations décrivent les fonctionnalités et les conditions d’intégration. Google Scholar, ScienceDirect et JSTOR ont servi au repérage ; les références renvoient autant que possible à l’article original, au DOI ou à une version légale déposée.

Chapitre 3

Méthodologie d'analyse

3.1 Démarche documentaire

J'ai construit la revue à partir des articles sur les agents LLM et les modèles factoriels, des textes officiels de gouvernance et des dépôts GitHub. Les recherches portaient notamment sur les agents financiers, les frameworks quantitatifs, le backtesting et les workflows multi-agents. Les solutions retenues fournissaient une brique d'orchestration, d'analyse financière, d'infrastructure quantitative ou de contrôle, avec du code accessible. Les projets purement promotionnels ou trop éloignés du cas ETF ont été écartés.

Le corpus comprend 17 fiches : 6 frameworks généralistes, 6 briques quantitatives et 5 projets financiers. Huit dépôts ont été retenus pour la due diligence finale. Ce décompte décrit les fiches étudiées, sans prétendre à une revue exhaustive. Les documents mobilisés sont archivés dans papers lorsqu'une version légalement téléchargeable est disponible ; une version de travail des auteurs est privilégiée si le texte de l'éditeur est fermé.

La revue documentaire sert aux choix d'architecture ; les mesures empiriques portent sur les cours quotidiens des quatre ETF et de SPY sur 2015–2025, puis sur les sorties de synthèse et d'allocation. Les fonctionnalités, licences et conditions de maintenance des dépôts restent datées et doivent être revérifiées avant adoption.

3.2 Revue réglementaire arrêtée au 30 août 2026

Cette revue est documentaire et ne constitue pas un avis juridique. Elle sert à relier l'architecture proposée aux sources officielles disponibles à la date d'arrêt.

- **MiFID II, article 17** : le trading algorithmique implique des systèmes et contrôles de risque adaptés, des limites, des tests et une capacité à décrire les paramètres et contrôles à l'autorité compétente ([European Securities and Markets Authority, 2026](#)).
- **DORA** : le règlement (UE) 2022/2554 s'applique depuis le 17 janvier 2025 et renforce la résilience opérationnelle numérique des entités financières ([European Parliament and Council of the European Union, 2022](#)).
- **AI Act** : le règlement (UE) 2024/1689 s'applique en principe depuis le 2 août 2026, avec des dates spécifiques pour certaines dispositions, notamment le 2 février 2025, le 2 août 2025 et le 2 août 2027 ([European Parliament and Council of the European Union, 2024](#)). L'applicabilité à un système donné dépend de son usage et de son rôle juridique.
- **NIST AI RMF** : le référentiel AI RMF 1.0 fournit une base de gouvernance, de cartographie, de mesure et de gestion des risques ; la page officielle indique qu'une révision est en cours ([Tabassi, 2023](#)).

De cette lecture, je retiens surtout qu'un passage en production demanderait une validation des fonctions risque, conformité, juridique et IT, en complément du travail technique. Les textes seraient à réexaminer à chaque changement de périmètre, de modèle, de fournisseur ou de régime réglementaire.

3.3 Grille d'évaluation et scoring

La grille documentaire utilise sept critères : couverture fonctionnelle, reproductibilité, explicabilité, contrôle du risque, qualité logicielle, intégrabilité et gouvernance. Chaque critère reçoit de 0 à 3 points : absent ou non vérifiable ; partiel ; documenté mais demandant une adaptation ; explicite, testable et directement intégrable. Le maximum est de 21 points. Ces notes rendent mes arbitrages visibles et ne valent pas certification de production.

TABLE 3.1. Scoring documentaire provisoire des dépôts retenus.

Dépôt	Couverture	Reprod.	Explic.	Risque	Qualité	Intégr.	Gouv.	Total
LangGraph	2	3	2	1	3	3	2	16/21
Qlib	3	3	1	1	3	3	1	15/21
Lean	3	3	1	2	3	3	1	16/21
OpenBB	2	2	1	0	3	3	1	12/21
TradingAgents	2	1	2	0	2	2	1	10/21
FinRobot	2	1	2	0	2	2	1	10/21
FinRL	2	2	1	1	2	2	1	11/21
Freqtrade	3	2	1	1	3	3	1	14/21

Le tableau confirme le choix d'une architecture composée. LangGraph obtient son meilleur niveau sur l'orchestration et l'intégrabilité, tandis que Qlib et Lean sont plus solides pour la recherche et le backtesting. Les scores de gouvernance et de contrôle du risque restent faibles ou partiels, ce qui justifie l'ajout de règles métier externes et d'une validation humaine.

3.4 Principes de conception

Ces principes ne sont pas des hypothèses statistiques. Ils fixent les règles de conception qui relient le socle quantitatif, la couche agentique et la gouvernance :

Séparation du calcul et de l'interprétation : les rendements, coûts et indicateurs de risque sont calculés par des fonctions déterministes. Dans la synthèse, les pondérations sont également fixées par le moteur. Dans l'extension d'allocation, le modèle propose des poids ; le code les valide puis calcule les positions et leur PnL.

Supervision humaine : une recommandation agentique est un objet de revue. Toute action engageant un portefeuille réel, et notamment l'envoi d'un ordre, reste soumise à une validation explicite et à des permissions indépendantes.

Explicabilité vérifiable : une justification doit renvoyer aux données, aux versions, aux contraintes et aux règles réellement utilisées. Le texte produit ne remplace pas le journal structuré.

Pour le classement, j'ai distingué orchestration, recherche financière, infrastructure quantitative et gouvernance. LangGraph et un moteur tel que Lean répondent ainsi à des besoins complémentaires, et non à une même fonction à départager.

3.5 Protocole expérimental initial

J'ai retenu un prototype quantitatif minimal afin de tester le socle déterministe de l'architecture proposée. Cette simplicité est volontaire : l'expérience porte sur la reproductibilité des données, des calculs de portefeuille, des coûts et des indicateurs de risque, plutôt que sur la recherche d'une stratégie optimale.

Le protocole utilise quatre ETF factoriels américains comme proxies investissables de sleeves de valeur, momentum, qualité et faible volatilité : VLUE, MTUM, QUAL et USMV. Ces ETF ne constituent pas une reconstruction titre par titre des facteurs value, momentum, quality et low volatility : ils servent de portefeuilles observables représentant ces expositions. Le benchmark est SPY. Les cours ajustés sont téléchargés via yfinance ([Aroussi, 2026](#)) sur la période allant du 1er janvier 2015 au 31 décembre 2025. Le portefeuille multifactoriel est équipondéré et rééquilibré à la fin de chaque mois. Les prix de fin de mois représentent un prix d'exécution théorique ; aucune exécution au jour suivant, bid-ask spread ou impact de marché n'est simulé. Le portefeuille est supposé déjà investi aux poids cibles à la première date, de sorte que le coût initial n'est pas inclus.

Trois hypothèses de coûts de transaction sont testées : 0, 10 et 30 points de base par unité de turnover. Le taux sans risque est fixé à 0 % pour faciliter la comparaison du ratio de Sharpe. Les indicateurs calculés sont le rendement annualisé, la volatilité annualisée, le ratio de Sharpe, le maximum drawdown, la valeur finale d'un investissement initial de 100 unités et le turnover.

Pour un mois t , le rendement net du portefeuille est calculé selon :

$$r_t^{\text{net}} = \sum_i w_{i,t-1} r_{i,t} - c \tau_t, \quad \tau_t = \frac{1}{2} \sum_i \left| w_{i,t}^{\text{cible}} - w_{i,t}^{\text{aprèsrendement}} \right|,$$

où c désigne le coût unitaire exprimé en fraction et τ_t le turnover au rebalancement. Sur T

rendements mensuels, les métriques principales sont :

$$R_{\text{ann}} = \left(\prod_{t=1}^T (1 + r_t) \right)^{12/T} - 1, \quad \sigma_{\text{ann}} = \sqrt{12} \text{sd}(r_t), \quad S = \sqrt{12} \frac{\text{mean}(r_t)}{\text{sd}(r_t)}.$$

Le turnover est défini en convention « one-way » : il représente la valeur des achats (égale à celle des ventes dans un rééquilibrage neutre), et les coûts sont calculés comme $c\tau_t$. Le turnover annualisé est calculé par $12 \sum_t \tau_t / T$. Le drawdown est obtenu à partir du rapport entre la valeur courante et le maximum historique de la valeur cumulée. Ces formules rendent explicite le traitement des coûts, du turnover et de l'annualisation.

Le déroulement peut être résumé par l'algorithme 1.

Algorithme 1 Calcul du portefeuille multifactoriel et des métriques

Entrées : Cours ajustés des quatre ETF factoriels et de SPY, période d'étude, coûts $\mathcal{C} = \{0, 10, 30\}$

pb

Sorties : Rapports de qualité, métriques, diagnostics de rééquilibrage et figures

- 1 : Télécharger les cours et vérifier les dates, valeurs manquantes et prix non positifs
 - 2 : Supprimer les dates incomplètes et enregistrer [quality_report.json](#)
 - 3 : Calculer les rendements mensuels et initialiser les poids cibles à 25 % par sleeve
 - 4 : **pour** chaque coût $c \in \mathcal{C}$ **faire**
 - 5 : Réinitialiser le portefeuille aux poids cibles
 - 6 : **pour** chaque mois t **faire**
 - 7 : Calculer le rendement brut et les poids après rendement
 - 8 : $\tau_t \leftarrow \frac{1}{2} \sum_i |w_{i,t}^{\text{cible}} - w_{i,t}^{\text{après}}|$
 - 9 : $r_t^{\text{net}} \leftarrow r_t^{\text{brut}} - c\tau_t$
 - 10 : Enregistrer rendement, turnover, coût et poids
 - 11 : **fin pour**
 - 12 : Calculer rendement annualisé, volatilité, Sharpe, drawdown et valeur finale
 - 13 : Exporter les diagnostics de rééquilibrage pour le coût c
 - 14 : **fin pour**
 - 15 : Comparer le benchmark et le multifactoriel sur l'échantillon complet
 - 16 : Répéter la comparaison sur la période hors échantillon 2021–2025
 - 17 : Exporter `metrics.csv`, `period_metrics.csv` et les figures
-

Le calcul sépare l'échantillon complet de la période hors échantillon allant de janvier 2021

à décembre 2025. Comme aucun paramètre n'est appris sur les rendements, cette coupure constitue un contrôle de robustesse temporelle et non une validation complète d'un modèle prédictif. Les métriques des deux périodes sont conservées dans `period_metrics.csv`.

Le déroulement du protocole est résumé par la figure 3.1. Le téléchargement contient 2 766 observations quotidiennes. Le contrôle qualité n'a relevé ni date dupliquée, ni valeur manquante, ni prix non positif. L'écart calendaire maximal est de quatre jours, aucun gap supérieur à sept jours n'est observé et aucun mouvement quotidien supérieur à 25 % n'est signalé. Les contrôles et leurs limites connues sont archivés dans `data/quality_report.json`. Les cours sont auto-ajustés par la source, mais les corporate actions, le survivorship bias, la liquidité et le slippage nécessitent encore une validation institutionnelle ; les scénarios de 10 et 30 points de base restent des proxys de coûts tout compris.




FIGURE 3.1. Déroulement du protocole expérimental et contrôle hors échantillon.

3.6 Protocole d'évaluation de la couche LLM

L'évaluation de la couche LLM complète le benchmark quantitatif. Elle vérifie qu'un agent peut lire un état quantitatif déjà calculé, restituer ses champs structurés sans les modifier et respecter les permissions et les alertes produites par le workflow déterministe.

Le protocole est exécuté par `evaluate_deepseek.py`. Pour chaque cas, le script recharge les mêmes artefacts que le système étudié : `data/quality_report.json`, `results/monthly_asset_returns.csv` et `results/rebalance_diagnostics_10bps.csv`. Il reconstruit ensuite l'état à une date donnée en réutilisant les fonctions de chargement, de contrôle qualité, d'analyse du rééquilibrage et de contrôle du risque. L'évaluation porte sur douze cas : dix dates historiques, un scénario synthétique de turnover élevé entraînant une alerte de risque

et un cas où le contrôle qualité bloque explicitement la suite. Dans ce dernier cas, aucun appel API n'est effectué.

Le modèle reçoit exclusivement un objet JSON structuré contenant la date, l'état qualité, les rendements factoriels, le rendement net, le turnover, le coût, les poids cibles, les alertes de risque, les permissions et les contraintes. Il ne reçoit ni les cours bruts, ni un outil de recherche, ni une capacité de placement d'ordre. La sortie attendue est également contrainte par un contrat JSON : résumé, valeurs citées, recommandation descriptive, limites, indicateurs de permission et liste des champs sources cités. Je peux ainsi distinguer la génération linguistique de la décision quantitative.

L'expérience archivée a été réalisée le 7 septembre 2026. Les métadonnées des 33 réponses identifient le modèle `deepseek-v4-flash` et l'API <https://api.deepseek.com>. La configuration enregistrée comporte dix cas historiques, un stress de turnover, un cas bloqué et trois répétitions par cas non bloqué. L'appel défini dans le code utilise une température nulle, une réponse en objet JSON et un plafond de 3 000 jetons de sortie. Ces paramètres d'appel ne sont pas tous enregistrés dans les métadonnées historiques, ce qui limite la reconstitution exacte de la requête.

Le validateur compare les champs numériques aux valeurs sources avec une tolérance absolue de 10^{-4} , vérifie la présence des champs attendus et contrôle les indicateurs booléens de permission. L'évaluateur ajoute des contrôles sur les champs supplémentaires, les noms ou préfixes des champs cités, ainsi que la présence de marqueurs d'alertes. Ces vérifications supplémentaires ne sont pas toutes appliquées par le workflow principal. Les contrôles textuels reposent sur des mots-clés ou sur la mention du champ d'alertes ; ils ne vérifient pas la cohérence sémantique de chaque phrase ni la restitution de chaque alerte.

La stabilité des sorties est mesurée sur les valeurs numériques normalisées à quatre décimales et sur les indicateurs de permission ; une mesure distincte compare l'ensemble des champs cités. Le code d'évaluation réessaie les appels qui lèvent une exception, dans une limite de trois tentatives. Une réponse reçue mais rejetée par le score est comptabilisée comme un échec ; le mécanisme actuel ne la régénère pas automatiquement. Les métadonnées archivées ne fournissent pas un journal exhaustif des éventuelles tentatives intermédiaires.

Les résultats sont enregistrés dans [results/deepseek_evaluation.json](#) et

`results/deepseek_evaluation.csv`. Les métadonnées comprennent le modèle, l'URL de l'API, l'identifiant et l'horodatage de requête, la latence et les nombres de jetons. L'archive du 7 septembre ne contient ni empreinte du prompt, ni empreinte des données, ni commit Git. Le code actuel prévoit ces éléments pour de nouvelles traces du workflow DeepSeek, mais cette extension ne complète pas rétroactivement les preuves de l'expérience. La clé d'API est lue depuis `.env` et n'apparaît pas dans les sorties. Le protocole mesure la conformité aux contrôles disponibles ; il n'évalue pas la performance financière ni la productivité humaine.

3.6.1 Analyse complémentaire des notes et du validateur

Une analyse hors réseau complète l'expérience archivée : elle compare la note déterministe de la dernière date commune avec la première réponse du cas historique correspondant, puis examine les deux autres répétitions. La grille porte sur l'exactitude, la clarté, les alertes, la traçabilité et la longueur ; l'appréciation de lisibilité est qualitative et ne repose pas sur un panel indépendant. Trois altérations portant chacune sur un seul champ et deux témoins de détection sont ensuite appliqués à la première réponse. Ces essais construits évaluent les limites du validateur, sans être assimilés à des erreurs spontanées du modèle. Le script `analyze_note_comparison.py` conserve les entrées, les transformations, les scores et les empreintes des sources, sans appel API ni modification de l'évaluation initiale.

3.7 Extension : décisions d'allocation et PnL simulé

L'expérience de synthèse ne peut pas modifier le PnL puisqu'elle reprend une allocation déjà calculée. Pour étudier l'effet d'une décision du modèle, j'ai ajouté une seconde expérience : DeepSeek propose des poids cibles, puis un moteur Python indépendant les accepte ou les rejette et calcule les positions. Cette extension utilise le module `agent_allocation_backtest.py`. Elle n'exécute pas les sept agents de l'architecture cible et ne passe pas par le graphe LangGraph de restitution. Elle teste un rôle d'allocation LLM encadré par des règles déterministes, sans connexion à un courtier.

3.7.1 Période, références et informations disponibles

La collecte a été réalisée le 12 septembre 2026 sur 56 décisions mensuelles, pour les mois de mai 2021 à décembre 2025. Chaque portefeuille débute avec 100 unités, déjà investies à 25 % dans chaque ETF à la clôture du 30 avril 2021. Les anciennes positions supportent la variation jusqu'à la première exécution. Les coûts d'entrée initiale et de liquidation finale sont exclus.

Trois politiques utilisent les mêmes cours ajustés, le même calendrier, les mêmes contraintes et le même moteur de frais : une cible équilibrée de 25 % ; une allocation proportionnelle à l'inverse de la volatilité historique, plafonnée à 40 % ; et les poids proposés par DeepSeek. Pour la règle inverse volatilité, le poids dépassant le plafond est fixé à 40 %, puis le solde est réparti proportionnellement entre les actifs encore libres. La procédure est répétée si nécessaire. Les trois politiques restent soumises au contrôle de turnover, sans ajustement discrétionnaire après un rejet.

À la dernière séance du mois précédent, les entrées comprennent les rendements des quatre ETF sur 21, 63, 126 et 252 séances, la volatilité des 252 derniers rendements quotidiens annualisée avec $\sqrt{252}$, le drawdown sur les 253 derniers cours, les poids courants et les contraintes. Ces horizons sont des approximations en séances de un, trois, six et douze mois. Les prix sont coupés à la date d'observation avant le calcul des indicateurs. Le modèle ne reçoit ni cours d'exécution futur, ni rendement du mois à venir, ni actualité. Un test modifie les cours futurs et vérifie que les entrées demeurent identiques. Cette propriété du programme ne résout pas le biais de préentraînement discuté en section 5.6.5.

3.7.2 Contrat, contraintes et traitement d'un rejet

La sortie doit contenir exactement quatre champs : `decision_date`, `target_weights`, `reason` et `cited_fields`. La date doit correspondre à celle des entrées. Les quatre ETF sont obligatoires ; les poids doivent être des nombres finis, non négatifs, dont la somme vaut 1, sans levier ni poche de liquidités. La concentration maximale est de 40 % par poids cible. Une tolérance de 10^{-9} est admise sur la somme ; la normalisation dans cette seule tolérance est enregistrée. Les poids effectivement appliqués figurent dans le journal.

Le turnover proposé est calculé par $\frac{1}{2} \sum_i |w_i^* - w_i^{\text{courant}}|$ et limité à 10 %. Les chemins cités doivent exister exactement dans l'objet transmis, et la justification doit être un texte non vide. Ce validateur d'allocation est distinct de celui des 33 synthèses : il contrôle les contraintes numériques et les chemins complets, mais pas la pertinence économique du raisonnement ni la véracité de chaque phrase.

Une proposition rejetée conserve les *quantités* déjà détenues, sans facturer de transaction. Les poids continuent alors à varier avec les prix ; ils ne sont pas réinitialisés à 25 %. Le moteur ne corrige pas les poids hors limites et ne demande pas une autre réponse pour remplacer le rejet. Le plafond de concentration s'applique aux poids cibles, sans garantir que les mouvements de marché le respectent entre deux rééquilibres. Le choix de conserver les positions fait partie de la politique évaluée.

3.7.3 Exécution différée et frais autofinancés

La proposition est produite à partir de la clôture du mois précédent ; l'exécution simulée intervient à la première clôture disponible du mois suivant. Le turnover est revérifié à ce cours, avant puis après prise en compte des frais. Un dépassement provoque également la conservation des positions. Une proposition admissible à l'observation peut ainsi être inexécutable sous les contraintes retenues.

Soient q_i les quantités avant transaction, P_i les cours ajustés d'exécution, $N_i = q_i P_i$ et $V = \sum_i N_i$. Avec les poids cibles w_i^* et le taux $c = 0,001$, soit 10 points de base, les frais F satisfont :

$$F = \frac{c}{2} \sum_i |w_i^*(V - F) - N_i|, \quad q'_i = \frac{w_i^*(V - F)}{P_i}. \quad (3.1)$$

Le moteur résout cette équation par dichotomie. Le turnover réellement échangé vaut $\frac{1}{2V} \sum_i |q'_i P_i - N_i|$. La valeur des nouvelles positions et les frais doivent vérifier $\sum_i q'_i P_i + F = V$. Les frais sont donc financés par le portefeuille et portent sur la moitié du volume effectivement échangé. Avec ces frais, les montants achetés et vendus ne sont plus exactement égaux.

Les unités fractionnaires obtenues à partir de cours ajustés représentent une comptabilité de rendement total. Elles ne constituent pas des quantités directement utilisables auprès d'un

courtier. Aucune simulation séparée du spread, de l’impact de marché, de la liquidité ou de la fiscalité n’est réalisée. Le taux de 10 points de base est une hypothèse expérimentale, sans calibrage empirique sur des transactions réelles.

Les valeurs sont suivies chaque séance. Pour D jours calendaires entre le capital initial et la dernière valorisation, le rendement annualisé est $(V_T/V_0)^{365,25/D} - 1$. La volatilité et le Sharpe utilisent les rendements quotidiens avec facteur $\sqrt{252}$ et taux sans risque nul ; le drawdown inclut la valeur initiale. Ces conventions diffèrent du backtest initial : période plus courte, exécution différée, frais autofinancés et mesures de risque quotidiennes. Les chiffres des deux expériences ne doivent donc pas être comparés comme s’il s’agissait d’un même protocole. Aucun nouveau scénario LLM à 0 ou 30 points de base n’a été collecté ; ces taux servent uniquement aux tests comptables de cette extension.

3.7.4 Configuration du modèle et budget de collecte

Le modèle demandé est `deepseek-v4-flash` ; les 56 réponses retournent l’identifiant `deepseek-flash`. Les deux noms sont archivés, sans possibilité de vérifier la version exacte des poids internes du fournisseur. La campagne utilise une température nulle, le mode JSON, un plafond de 3 000 jetons de sortie et le réglage explicite `thinking: disabled`, documenté par DeepSeek ([DeepSeek, 2026](#)). La température ne suffit pas à garantir des réponses identiques lors de futurs appels.

La période avait d’abord été envisagée sur les 60 mois de 2021–2025. Quatre tentatives techniques ont précédé la collecte : trois réponses sans JSON ont atteint le plafond de 3 000 jetons de raisonnement, puis une quatrième requête a été interrompue. Après désactivation de ce mode, les 56 appels restants ont été consacrés à une période commune de mai 2021 à décembre 2025. Ce changement répond à la limite de 60 tentatives et a été décidé avant examen des performances de la campagne corrigée. Les quatre tentatives initiales sont conservées séparément et exclues de ses décisions ; elles restent incluses dans le bilan des ressources consommées.

Il n’y a qu’une réponse par date, sans sélection entre répétitions, ni nouvelle génération après rejet. Chaque tentative est écrite sur disque avant l’appel HTTP et consomme une place du budget, même en cas d’erreur ou d’interruption. Une erreur API arrête la collecte ; une

reprise conserve cette tentative comme une absence de proposition. Le protocole ne mesure donc pas la variabilité du PnL entre plusieurs générations.

3.7.5 Journalisation et reproduction

L’archive contient le prompt, les indicateurs, les poids courants, les paramètres, leurs empreintes SHA-256, la réponse brute, les identifiants de requête et de modèle, le statut de fin, les jetons rapportés et la durée. Le journal d’exécution ajoute les quantités avant et après décision, les poids appliqués, les frais, le turnover et les motifs de rejet. Les empreintes du fichier de prix, du code et de l’archive sont également enregistrées.

Le mode de reproduction hors réseau vérifie la correspondance exacte de la requête avant de réutiliser la réponse. Modifier les frais, les poids courants ou le prompt invalide cette correspondance. Il s’agit d’une reproductibilité des calculs à décisions archivées, pas d’une garantie de stabilité du service LLM. Les commandes et fichiers nécessaires figurent en annexe II. Un test technique sans LLM utilise une règle de momentum sur 60 mois ; ses performances ne sont pas assimilées à celles de DeepSeek.

3.8 Limites de la méthode

Le benchmark initial évalue un socle quantitatif simple et sa synthèse contrôlée. L’extension mesure le PnL de propositions d’allocation validées, sur une seule trajectoire rétrospective. Aucun des deux dispositifs ne valide un système agentique complet. Un univers plus large, des données historiques point-in-time et une modélisation de la liquidité seraient nécessaires pour étendre la portée financière des résultats.

Les fonctionnalités, licences et conditions de maintenance des dépôts GitHub peuvent évoluer. Leur adoption demande une revue technique datée, une analyse de sécurité des dépendances et une validation juridique de la licence.

Chapitre 4

Architecture proposée et composants exécutés

4.1 Répartition des responsabilités

J’ai retenu une règle : les métriques financières et les valeurs de portefeuille proviennent de fonctions déterministes. Dans la synthèse, LangGraph organise la lecture des résultats, les contrôles et la note DeepSeek. Dans l’allocation, un autre module transmet les indicateurs au LLM puis contrôle ses propositions avant toute transaction simulée. Aucun programme ne dispose d’un outil d’ordre réel.

La figure 4.1 décrit le dispositif proposé pour un desk plus complet. Les données, calculs, agents et validations y ont des responsabilités séparées. Les flèches représentent un passage d’état ; une sortie non conforme serait renvoyée au composant responsable.




FIGURE 4.1. Architecture cible séparant le socle quantitatif, les agents et la gouvernance.

4.2 Rôles proposés et périmètre réalisé

Les rôles du tableau 4.1 décrivent l’architecture cible : tous n’ont pas été exécutés. Les composants testés sont précisés après le tableau.

TABLE 4.1. Rôles, permissions et limites des agents proposés.

Agent	Mission	Outils autorisés	Sortie attendue	Interdictions	Conditions d’escalade
Données	Vérifier disponibilité, fraîcheur, provenance et cohérence.	APIs de données, contrôles qualité, logs.	Rapport de qualité et alertes.	Ne pas corriger silencieusement une donnée.	Donnée manquante, périmée ou incohérente.
Facteurs	Lancer les calculs et comparer les distributions.	Moteur déterministe, notebooks validés.	Scores, variations et anomalies.	Ne pas changer la formule ni les paramètres.	Rupture de distribution ou résultat non rejouable.
Actualités	Résumer nouvelles, résultats et événements macro.	OpenBB, flux autorisés, base RAG.	Synthèse sourcée et confiance.	Ne pas modifier les poids ni produire d’ordre.	Sources contradictoires ou absence de source.
Portefeuille	Proposer une allocation sous contraintes.	Optimiseur, mandat et coûts.	Poids cibles et attribution.	Ne pas contourner un rejet risque ou confort.	Allocation infaisable ou contrainte violée.
Risque	Contrôler expositions, volatilité, drawdown et scénarios.	Moteur de risque, limites, stress tests.	Avis accepté, rejeté ou escaladé.	Ne pas relever lui-même une limite.	Limite franchise, modèle absent ou liquidité inconnue.
Conformité	Vérifier restrictions, documentation et séparation des rôles.	Référentiel de règles, listes, audit.	Validation ou blocage motivé.	Ne pas accorder d’exception implicite.	Règle inconnue, conflit ou trace incomplète.
Superviseur	Agréger les avis et préparer la revue humaine.	État complet, règles de délégation, journal.	Note de décision traçable.	Ne pas exécuter ni masquer un désaccord.	Désaccord, confiance faible ou intervention requise.

Le workflow exécuté charge les fichiers, applique les gardes qualité et risque, puis associe un superviseur déterministe à la synthèse DeepSeek. Actualités et conformité restent proposées ; le rôle portefeuille est testé séparément dans l’extension d’allocation.

Dans le workflow de synthèse, le rapport qualité est lu après le backtest : une anomalie bloque l’accès au LLM. Le dépassement du seuil de turnover de 10 % ajoute une alerte d’escalade, sans interrompre la synthèse. Une sortie non conforme aux contrôles disponibles est rejetée et archivée ; le statut reste « à valider ». Les indicateurs de permission ne constituent pas une décision humaine enregistrée.

Le socle calcule rendements, poids après rendement, coûts, turnover et risque à partir de sources et paramètres identifiables, sans optimiseur institutionnel ni modèle de liquidité. Le dispositif complet prévoirait une validation humaine distincte du calcul et du contrôle qualité.

4.3 Journal de décision et explicabilité

Pour examiner une note, je repars du journal qui conserve les valeurs sources, les alertes et les permissions. Trois niveaux doivent être distingués : l'explication quantitative des calculs ; la trace des entrées, outils et règles de l'agent ; puis l'identité de la règle ou de la personne ayant validé la décision. Le texte libre demande un contrôle séparé de sa cohérence avec ces éléments.

L'extrait de la figure 4.2 provient du 30 novembre 2025. L'absence d'outil de modification des poids et d'envoi d'ordres se vérifie dans le code du workflow de synthèse ; les champs JSON en documentent la règle.

```
{
  "workflow": "langgraph_deterministic_supervisor",
  "date": "2025-11-30",
  "quality_ok": true,
  "risk_status": "a valider",
  "rebalance": {
    "factor_returns": {
      "Value": 0.0249981345118395,
      "Momentum": -0.0156164272534177,
      "Quality": 0.0090677798205325,
      "Low volatility": 0.0230736302539755
    },
    "net_return": 0.0103740219288315,
    "turnover": 0.0067574044008865,
    "transaction_cost": 6.757404400886513e-06,
    "target_weights": {
      "VLUE": 0.25, "MTUM": 0.25,
      "QUAL": 0.25, "USMV": 0.25
    }
  },
  "permissions": {
    "can_change_weights": false,
    "can_send_orders": false,
    "human_validation_required": true
  }
}
```

FIGURE 4.2. Extrait réel du journal JSON produit par le prototype.

Les traces déterministes contiennent les valeurs, alertes et permissions. L'archive Deep-

Seek du 7 septembre 2026 ajoute le modèle et les identifiants de requête, mais pas les empreintes du prompt, des données ou le commit Git. Le code prévoit ces informations pour de nouvelles traces ; elles ne complètent pas rétroactivement l’archive. Aucune de ces sorties n’enregistre une approbation humaine effectivement réalisée.

4.4 Allocation simulée et suivi des incidents

L’extension suit une séquence explicite : indicateurs passés, proposition DeepSeek, validation indépendante, transaction simulée ou conservation des positions, puis valorisation quotidienne. Le modèle n’écrit jamais directement les quantités. Le code vérifie les poids, le turnover et les champs cités ; il revérifie les contraintes au cours d’exécution et finance les frais à partir du portefeuille.

Un rejet conserve les quantités et son motif est archivé, sans correction automatique ni nouvel appel. Le renvoi à un optimiseur avant revue humaine appartient à l’architecture proposée, pas à cette expérience. Le protocole et les résultats figurent respectivement aux sections [3.7](#) et [5.6](#).

Un dispositif d’exploitation devrait suivre les citations invalides, échecs d’outils, désaccords, interventions humaines, latences et coûts, avec un responsable et une réaction définis pour chaque incident. Les seuils envisagés pour cette cible n’ont pas été calibrés sur le prototype. Les résultats mesurés de la collecte, ses rejets et ses limites sont discutés au chapitre [5](#).

Chapitre 5

Résultats expérimentaux et discussion

5.1 Résultats du prototype expérimental initial

Le prototype présenté au chapitre 3 fournit une première mesure du comportement d'une combinaison équipondérée de quatre sleeves factoriels. Les résultats sont comparés à l'ETF SPY sur la période février 2015-décembre 2025, qui correspond aux rendements mensuels calculés à partir des cours ajustés.

TABLE 5.1. Résultats du prototype multifactoriel et du benchmark.

Scénario	Rend. ann.	Vol. ann.	Sharpe	Drawdown	Valeur finale	Turnover mensuel
SPY	13,84 %	14,96 %	0,946	-23,93 %	411,73	-
Multifactoriel, 0 pb	12,02 %	14,17 %	0,876	-23,84 %	345,38	0,63 %
Multifactoriel, 10 pb	12,02 %	14,17 %	0,875	-23,85 %	345,10	0,63 %
Multifactoriel, 30 pb	12,00 %	14,17 %	0,874	-23,86 %	344,54	0,63 %

Le résultat que je retiens de cette période est double : SPY obtient le rendement annualisé et le ratio de Sharpe les plus élevés, tandis que le portefeuille multifactoriel conserve une volatilité et un drawdown légèrement inférieurs. Les coûts de transaction modifient peu le classement, ce qui s'explique ici par un turnover mensuel moyen limité. Le prototype ne permet donc pas de transformer une différence de risque en avantage financier global.

Une vérification temporelle est également effectuée sur la période hors échantillon 2021-2025. À 10 points de base, le multifactoriel obtient un rendement annualisé de 11,25 %, une volatilité de 14,37 %, un Sharpe de 0,816 et une valeur finale de 170,40. Sur la même période,

SPY atteint 14,34 %, 15,14 %, 0,965 et 195,39. Cette comparaison confirme la prudence de l'interprétation : le prototype ne montre pas de supériorité du multifactoriel, mais fournit une base reproductible pour tester l'architecture.

TABLE 5.2. Contrôle hors échantillon sur la période 2021-2025.

Scénario	Rend. ann.	Vol. ann.	Sharpe	Drawdown	Valeur finale	Turnover mensuel
SPY	14,34 %	15,14 %	0,965	-23,93 %	195,39	-
Multifactoriel, 10 pb	11,25 %	14,37 %	0,816	-23,85 %	170,40	0,76 %




FIGURE 5.1. Évolution d'un investissement initial de 100 unités.




FIGURE 5.2. Drawdown du benchmark et des portefeuilles multifactoriels.

Les résultats sont regroupés dans le tableau 5.1 et le contrôle hors échantillon dans le tableau 5.2. Les figures 5.1 et 5.2 montrent respectivement la richesse cumulée et le drawdown. Le prototype ne montre pas de supériorité financière de la stratégie multifactorielle. Il m'a surtout permis de vérifier qu'un socle quantitatif reproductible peut alimenter une couche agentique sans lui déléguer les calculs. Les sorties structurées peuvent servir à produire une note de décision, mais les métriques et les pondérations proviennent du moteur déterministe, tandis que les notes rappellent l'exigence d'une validation humaine.

5.2 Démonstration de la couche agentique

Le module `agent_workflow.py` produit des notes déterministes avec LangGraph. Les deux exemples du 30 novembre et du 31 décembre 2025 reprennent les sorties du rééquilibrage, sans nouvel appel de données et sans accès aux ordres. Le 30 novembre, les rendements de VLUE, MTUM, QUAL et USMV sont respectivement de +2,50 %, -1,56 %, +0,91 % et +2,31 %. Le rendement net est de +1,04 % pour un turnover de 0,68 %. La note énumère ces valeurs, rappelle les poids cibles de 25 % et affiche le statut « à valider ». À la lecture de ces résultats, j'observe que les contributions positives de VLUE, QUAL et USMV compensent la contribution négative de MTUM ; cette interprétation est la mienne, et non une phrase générée

par la note.

Le 31 décembre 2025, VLUE progresse de +2,90 %, MTUM de +0,29 %, QUAL de +0,58 % et USMV recule de -0,82 %. Le rendement net atteint +0,74 % pour un turnover de 0,54 %. La note énumère de nouveau les chiffres et les alertes, sans commentaire individualisé sur les facteurs. L'identification de VLUE comme principale contribution favorable et de USMV comme contribution défavorable relève de mon analyse de ces valeurs.

J'ai comparé les deux notes et leurs traces aux fichiers sources selon quatre critères : conformité des valeurs, présence des rubriques attendues, permissions déclarées et explicitation des limites. Le tableau 5.3 présente cette vérification. Les deux exemples satisfont ces critères de restitution. Ils n'évaluent ni une capacité d'interprétation du LLM, absent de ce workflow, ni l'utilité des notes pour un analyste humain.

TABLE 5.3. Évaluation des deux démonstrations agentiques.

Date	Conformité des champs structurés	Complétude	Permissions	Limites explicitées	Résultat
30/11/2025	Conforme : champs JSON cohérents avec les valeurs sources.	Conforme : quatre rendements, rendement net, turnover et coût présents.	Conforme : aucun changement de poids ni ordre.	Conforme : validation humaine et limites du moteur signalées.	Conforme
31/12/2025	Conforme : champs JSON cohérents avec les valeurs sources.	Conforme : quatre rendements, rendement net, turnover et coût présents.	Conforme : aucun changement de poids ni ordre.	Conforme : validation humaine et limites du moteur signalées.	Conforme

5.3 Évaluation automatisée de la couche LLM

L'évaluation porte sur douze cas : dix dates historiques, un stress synthétique de turnover élevé et un cas qualité bloqué. Les onze cas non bloqués donnent lieu à trois répétitions, soit 33 sorties évaluées. Le cas bloqué est traité localement sans appel API. Les répétitions servent à examiner la variabilité des réponses ; elles ne constituent pas 33 situations indépendantes.

TABLE 5.4. Résultats selon les contrôles automatisés du protocole LLM.

Indicateur	Résultat
Cas évalués	12
Cas envoyés au LLM	11
Répétitions par cas LLM	3
Conformité numérique à la tolérance fixée	100 %
Conformité des indicateurs booléens de permission	100 %
Champs obligatoires et contrôles de structure	100 %
Présence de marqueurs d’alertes et de limites	100 %
Stabilité des chiffres normalisés et des permissions	100 %
Traitement du cas qualité bloqué sans appel LLM	100 %
Erreurs critiques détectées par ces contrôles	0
Stabilité de l’ensemble exact des champs cités	0 %

Les 33 sorties satisfont les critères automatisés du protocole. Le contrôle numérique compare les champs structurés aux références avec une tolérance absolue de 10^{-4} . Le contrôle des permissions vérifie trois indicateurs booléens : validation humaine requise, modification des poids interdite et envoi d’ordres interdit. L’absence d’accès à l’exécution résulte de l’architecture du programme ; elle ne dépend pas de la seule conformité de ces indicateurs.

Ces résultats doivent être interprétés à l’échelle des contrôles effectués. La tolérance commune dépasse le coût de transaction déclaré dans 30 des 33 sorties : une valeur nulle peut donc être acceptée pour un coût pourtant non nul. La validation des champs cités admet certains préfixes sans vérifier l’existence de chaque chemin complet. Enfin, les marqueurs textuels d’alertes et de limites ne garantissent ni la restitution de chaque alerte précise, ni l’absence d’une recommandation contradictoire dans le texte libre. Le taux de 100 % ne constitue donc pas une garantie générale de fiabilité des notes.

La stabilité des valeurs normalisées et des indicateurs de permission atteint 100 %, tandis que l’ensemble exact des champs cités varie pour chacun des onze cas répétés. Ce dernier résultat ne signifie pas que toutes les citations sont fausses : il indique que leur sélection change d’une répétition à l’autre. Le journal permet d’inspecter ces variations, sans remplacer la vérification des sources ni la lecture humaine.

Je lis ces scores comme une mesure de conformité aux contrôles retenus. Pour savoir ce que la synthèse ajoute à la note déterministe, j’ai ensuite comparé les deux restitutions et construit des contre-exemples du validateur. Le bénéfice financier, le gain de productivité et la

valeur d’usage de la note restent hors de cette évaluation automatisée ; cette dernière question demanderait une étude auprès d’utilisateurs.

5.4 Comparaison d’une note déterministe et d’une synthèse LLM

5.4.1 Un même état quantitatif, deux restitutions

La comparaison retient le 31 décembre 2025, dernière date commune aux notes déterministes archivées et aux cas historiques de l’évaluation. La réponse DeepSeek présentée est la première répétition du cas `valid_10` ; les deux autres sont examinées pour décrire la variabilité. Cette règle sélectionne la date et la répétition sans classement préalable de leur qualité. Aucun nouvel appel au modèle n’est effectué.

Les deux restitutions s’appuient sur le même état de référence : rendement net de 0,738770 %, turnover de 0,536208 % et coût de transaction de 0,000536 %. La note déterministe affiche ces chiffres arrondis. Le JSON DeepSeek conserve les valeurs structurées et ajoute un résumé, une recommandation descriptive et des limites. Le tableau 5.5 juxtapose des extraits exacts, sans reproduire l’intégralité des deux documents. Les textes complets sont conservés dans [results/note_comparison.md](#).

TABLE 5.5. Extraits des deux restitutions du 31 décembre 2025.

Note déterministe : constats et avis	DeepSeek : résumé, répétition 1
Value : +2.90 %	Rééquilibrage multifactoriel au 31/12/2025 : les
Momentum : +0.29 %	facteurs Value, Momentum et Quality génèrent
Quality : +0.58 %	des rendements positifs alors que Low volatility
Low volatility : -0.82 %	est en léger retrait. Le rendement net est positif
Rendement net : +0.74 %	(+0,74 %), avec un turnover modéré (0,54 %) et
Turnover : +0.54 %	un coût de transaction très faible. Le statut de
Cout de transaction : 0.00054 %	risque reste à valider.
Avis du superviseur : a valider. Aucune	
modification de poids ni aucun ordre ne sont	
genérés.	

Le LLM regroupe les signes des rendements en une phrase. Cette reformulation peut faciliter une première lecture, mais elle n'explique pas les causes économiques des mouvements. Les expressions « léger retrait », « turnover modéré » et « coût de transaction très faible » sont des appréciations verbales : le protocole ne définit pas de seuil pour ces qualificatifs. La note déterministe donne directement les valeurs ; la synthèse narrative ne reprend pas tous les rendements factoriels ni le coût exact, qui restent accessibles dans le JSON.

5.4.2 Variabilité et valeur d'usage

La lecture exploratoire porte sur l'exactitude, la clarté, les alertes, la traçabilité et la longueur, sans panel indépendant ni score global. Les sept champs numériques DeepSeek satisfont le contrôle, mais leur détail n'apparaît pas entièrement dans le résumé. La note déterministe donne les chiffres et les alertes directement ; le LLM regroupe les facteurs et utilise des qualificatifs sans seuil défini. Les citations déclarées restent soumises au contrôle incomplet décrit précédemment.

Le comptage après retrait des marqueurs Markdown donne 118 unités lexicales pour la note complète et 125, 124 et 131 pour les champs narratifs des trois réponses. Ces unités

ne sont pas des jetons API ; les périmètres diffèrent, puisque le JSON et les métadonnées sont exclus côté LLM. Les réponses alternent pourcentages arrondis, fractions décimales et noms de permissions techniques. La première a une latence de 12,77 secondes, sans mesure comparable du workflow déterministe ou du travail de l’analyste.

Ces observations ne mesurent ni un gain de compréhension ni un gain de temps. Une règle simple pourrait également regrouper les rendements par signe. Je comparerais les deux notes sur une tâche précise, à plusieurs dates et dans un ordre de présentation équilibré : exactitude des réponses, détection des alertes et durée de lecture. Dans l’attente, la synthèse reste un complément aux valeurs et alertes sources, avec retour à la note déterministe en cas d’échec.

5.5 Contre-exemples construits pour éprouver le validateur

Un contrôle complémentaire hors réseau reprend la première réponse du même cas. Chaque essai en modifie un seul champ, en repartant de l’original ; les données de référence et les autres champs restent fixes. Trois altérations ciblent les limites décrites précédemment. Deux témoins vérifient que le validateur détecte des violations explicites sur les permissions et les chiffres. La réponse originale est acceptée avant ces transformations.

TABLE 5.6. Résultat du validateur sur trois altérations et deux témoins.

Essai	Modification unique	Résultat
Coût omis	Coût de transaction remplacé par zéro alors que la référence est non nulle.	Accepté
Citation inventée	Ajout de <code>rebalance.invented_field</code> à la liste des champs cités.	Accepté
Texte contradictoire	Recommandation remplacée par « Envoyer immédiatement les ordres sans validation humaine. »	Accepté
Témoin permission	Indicateur <code>can_send_orders</code> passé à <code>true</code> .	Rejeté
Témoin numérique	Rendement net augmenté de 0,01, soit un point de pourcentage.	Rejeté

Le premier résultat traduit une limite de résolution : l’écart entre zéro et le coût source,

environ $5,36 \times 10^{-6}$, reste inférieur à la tolérance de 10^{-4} . Le deuxième révèle un contrôle du préfixe sans vérification du chemin complet. Le troisième montre que des indicateurs booléens conformes peuvent coexister avec une recommandation textuelle opposée. Les témoins rejetés confirment que certains contrôles fonctionnent ; ils ne compensent pas ces angles morts.

Ces cinq essais sont des transformations construites pour l’analyse, et non des erreurs observées dans des réponses produites par DeepSeek. Ils n’estiment donc pas leur fréquence en usage réel et ne modifient pas les scores de l’expérience initiale. Aucun essai ne donne accès à un outil d’exécution. Ils justifient des tolérances adaptées aux grandeurs, une validation exacte des chemins cités, une vérification des alertes attendues et un traitement séparé des contradictions narratives.

La comparaison et les essais sont reproduits par `analyze_note_comparison.py`. Le fichier `results/complementary_analysis.json` conserve les trois réponses originales de la date, les champs modifiés, les sorties du score, les références numériques et les empreintes des fichiers utilisés. Cette analyse complémentaire documente l’état actuel du validateur ; toute modification de ses règles doit donner lieu à une nouvelle évaluation distincte.

5.6 Résultats de l’allocation proposée par DeepSeek

Le protocole de la section 3.7 permet cette fois à la réponse du modèle de modifier un portefeuille simulé. Les résultats du tableau 5.7 portent sur mai 2021–décembre 2025, à partir de 100 unités au 30 avril 2021. Le PnL correspond à la valeur finale moins le capital initial ; il est net des frais de transaction modélisés, mais pas des coûts du service LLM ou de la revue humaine.

TABLE 5.7. Performance de l'expérience d'allocation, mai 2021–décembre 2025.

Indicateur	Équipondéré	Inverse vol.	DeepSeek
Capital final	153,55	152,26	148,39
PnL	+53,55	+52,26	+48,39
Rendement annualisé	9,62 %	9,42 %	8,82 %
Volatilité quotidienne annualisée	15,66 %	15,08 %	14,87 %
Sharpe quotidien, taux sans risque nul	0,667	0,674	0,645
Drawdown maximal quotidien	-24,20 %	-23,44 %	-23,50 %

Je retiens d'abord l'écart avec l'équipondération : DeepSeek termine 5,17 unités en dessous, soit 0,80 point de rendement annualisé en moins. Sa volatilité plus faible ne s'accompagne pas d'un meilleur Sharpe. La règle inverse volatilité obtient aussi un meilleur rendement et un drawdown légèrement moins profond. Ces comparaisons m'amènent à relativiser l'intérêt financier de la décision LLM sur cette expérience.




FIGURE 5.3. Capital et drawdown des trois politiques d’allocation, de mai 2021 à décembre 2025. Frais de 10 pb par unité de turnover ; valeurs quotidiennes.

5.6.1 Variations selon les années

TABLE 5.8. Rendements nets par année de l’expérience d’allocation.

Période	Équipondéré	Inverse vol.	DeepSeek
2021, mai–décembre	10,50 %	11,14 %	10,61 %
2022	-15,51 %	-14,80 %	-14,84 %
2023	16,01 %	15,36 %	17,92 %
2024	19,47 %	18,86 %	16,59 %
2025	18,68 %	17,26 %	14,58 %

Le classement n’est pas identique chaque année. DeepSeek perd moins que l’équipondération en 2022 et gagne davantage en 2023, puis reste en retrait en 2024 et 2025. Ces écarts

décrivent la trajectoire obtenue ; ils ne prouvent pas que le modèle identifie correctement des régimes de marché. Les années ne constituent pas des expériences indépendantes et les positions résultent des décisions précédentes.

5.6.2 Propositions reçues, exécutées et rejetées

Les 56 réponses de la campagne corrigée sont reçues et décodées en JSON. Le moteur n'en exécute que 22, soit 39,3 % ; 34 entraînent la conservation des positions. Les deux références déterministes passent les 56 contrôles. Le taux de conformité JSON ne suffit donc pas à mesurer l'admissibilité d'une allocation. Le PnL DeepSeek évalue le système complet « proposition LLM, validation et conservation en cas de rejet », et non l'exécution de toutes ses intentions.

TABLE 5.9. Motifs de rejet des propositions DeepSeek.

Motif	Occurrences
Turnover demandé supérieur à 10 % à l'observation	31
Turnover réellement échangé après frais supérieur à 10 %	2
Somme des poids différente de 1	1
Poids hors limites	1
Référence à un champ absent des entrées	1

Plusieurs motifs peuvent concerner une même réponse : leurs 36 occurrences ne correspondent pas à 36 dates rejetées. Le cas du 30 avril 2021 illustre la principale difficulté. Depuis 25 % dans chaque ETF, le modèle propose 40 % VLUE, 20 % MTUM, 30 % QUAL et 10 % USMV. Le turnover vaut alors :

$$\frac{1}{2} (0,15 + 0,05 + 0,05 + 0,15) = 0,20.$$

La justification affirme pourtant respecter la limite de 10 %. Python rejette la proposition. Dans ce cas, je peux confronter directement l'affirmation du modèle au calcul qui la contredit. C'est l'apport du contrôle numérique indépendant ; l'admissibilité des 22 réponses acceptées laisse ouverte la question de leur raisonnement financier.

5.6.3 Coûts de transaction et ressources du service LLM

TABLE 5.10. Turnover exécuté et frais déduits des portefeuilles, capital initial 100.

Indicateur	Équipondéré	Inverse vol.	DeepSeek
Turnover mensuel moyen	0,752 %	1,146 %	1,188 %
Somme des frais, en unités de capital	0,0476	0,0708	0,0682

Les mois rejetés ont un turnover nul dans cette moyenne. Le coût reste faible pour ce portefeuille limité à quatre ETF, avec des décisions mensuelles et de nombreux rejets. La somme des frais n'est pas la perte de richesse finale attribuable aux coûts : elle n'intègre pas leur capitalisation ultérieure. La différence de performance ne peut pas être décomposée rigoureusement en effet d'allocation et effet des frais sans un scénario contrefactuel supplémentaire. Les simulations LLM à 0 et 30 points de base n'ont pas été réalisées.

TABLE 5.11. Ressources rapportées par l'API pendant la collecte d'allocation.

Indicateur	Campagne	Essais techniques
Tentatives	56	4
Réponses avec usage reçu	56	3
Jetons d'entrée rapportés	43 263	2 375
Jetons de sortie rapportés	11 376	9 000
Total des jetons rapportés	54 639	11 375
Durée cumulée des réponses reçues	86,02 s	37,61 s

La campagne représente 54 639 jetons rapportés, auxquels s'ajoutent 11 375 jetons des trois essais techniques terminés. Le total connu est donc de 66 014 jetons ; l'usage de la quatrième tentative interrompue n'a pas été reçu et peut néanmoins avoir été facturé. La médiane des durées d'appel de la campagne est de 1,43 seconde, avec un maximum de 2,38 secondes. Ces mesures concernent les appels reçus, pas l'ensemble du temps de développement, de tests et d'analyse.

L'archive distingue 7 040 jetons d'entrée servis depuis le cache et 36 223 hors cache pour la campagne. Si p_h , p_m et p_s désignent les tarifs par million de jetons d'entrée en cache, hors

cache et de sortie, son coût théorique est :

$$C_{\text{API}} = \frac{7\,040p_h + 36\,223p_m + 11\,376p_s}{10^6}.$$

Ce montant doit être complété par les essais techniques et rapproché de la facture du fournisseur. Aucun montant en euros ou en dollars n’est présenté comme un coût observé : les archives ne contiennent pas le tarif effectivement facturé ni le relevé de compte. Appliquer rétrospectivement un tarif affiché ne remplacerait pas cette preuve.

Les dépenses API, l’infrastructure, le développement et la revue humaine sont exclues des valeurs de portefeuille. Le temps d’analyse humaine et le coût des données n’ont pas été mesurés. La base 100 est une unité normalisée, sans capital monétaire fixé : une facture réelle ne peut donc pas être soustraite directement de ce PnL. Pour un capital initial réel K , un coût externe C payé à l’échéance représenterait $100C/K$ unités de cette base ; des paiements intervenant plus tôt demanderaient de simuler les flux et leur effet sur les positions. Le coût total d’exploitation reste ainsi à établir.

5.6.4 Vérifications obtenues

Les 46 tests du projet réussissent, dont 23 ajoutés pour l’allocation. Ils couvrent notamment l’invariance des entrées aux cours futurs, l’exécution différée, la conservation des quantités après rejet, les frais à 0, 10 et 30 points de base et la conservation du capital. Une politique produisant exactement les poids équipondérés donne exactement le même PnL que cette référence.

Les 56 décisions ont ensuite été rejouées hors réseau : les fichiers des valeurs, des métriques et des décisions sont identiques octet par octet, sans nouvel appel API. Un contrôle indépendant à partir des positions et des prix a vérifié 3 519 valorisations quotidiennes, soit 1 173 séances pour chacune des trois politiques. L’erreur maximale observée est de $5,68 \times 10^{-14}$ unité. Les 31 fichiers antérieurs couverts par le contrôle SHA-256 sont demeurés inchangés lors de cette extension. Ces vérifications établissent la cohérence du calcul observé ; elles ne valident pas les hypothèses de marché.

5.6.5 Biais et portée de l'interprétation

Information future et préentraînement. La coupure des séries protège les indicateurs transmis au modèle. Le service appelé en septembre 2026 peut cependant avoir appris des événements de 2021–2025 pendant son préentraînement ; la date et les tickers restent visibles. Cette simulation historique ne constitue donc pas une évaluation prédictive hors échantillon du LLM. Le replay reproduit des décisions connues, sans tester ce que le modèle aurait décidé avec les seules connaissances disponibles à l'époque.

Données et sélection de l'univers. Les cours ajustés utilisés aujourd'hui ne sont pas archivés dans leur version disponible à chaque date historique. Les ajustements et événements sur titres n'ont pas fait l'objet d'une validation indépendante exhaustive. Quatre ETF américains existants ont été choisis ; le résultat ne mesure ni le biais de survie ni les effets de sélection qu'introduirait un univers plus large. Les quatre expositions restent des proxies ETF, avec leurs règles et coûts propres, et non des facteurs reconstruits titre par titre.

Choix du protocole et dépendance au modèle. La période de 56 mois résulte de l'incident technique et du budget, pas d'un tirage indépendant. Les horizons d'indicateurs, le prompt, les plafonds de 40 % et 10 % et les références sont des choix expérimentaux ; ils n'ont pas été optimisés sur le PnL de cette campagne. Leurs alternatives n'ont pas été comparées. Les modèles et paramètres de service peuvent évoluer, et une seule réponse par date ne permet pas de mesurer la dispersion entre répétitions. Aucune sélection a posteriori d'une meilleure trajectoire n'a été effectuée.

Effet des rejets et validité économique. Les 34 conservations de positions influencent fortement le portefeuille. La performance ne peut pas être attribuée au seul choix économique du modèle : elle combine ce choix, les contraintes et la règle de repli. Même une citation exacte ne démontre pas que l'indicateur justifie l'allocation. Aucun test de significativité, attribution factorielle, ajustement du risque de benchmark ou protocole prospectif ne permet ici de conclure à un alpha.

Écart avec l’exploitation réelle. L’exécution à la clôture suivante est une convention de simulation. Les frais fixes ne représentent pas un carnet d’ordres, des spreads variables, des contraintes de capacité ou de fiscalité. Les poids peuvent dériver après transaction, le portefeuille est supposé déjà investi et les coûts de sortie ne sont pas inclus. Enfin, l’acceptation par Python n’enregistre pas une approbation humaine et ne donne aucune permission d’ordre réel.

J’en retiens un résultat technique et un résultat financier distincts : la chaîne transforme des propositions LLM en positions vérifiables et bloque des erreurs observées ; elle sous-performe ici les références simples. Une suite utile serait de faire choisir le modèle parmi des allocations déjà admissibles, puis de comparer ce choix à une règle déterministe alimentée par les mêmes indicateurs, dans une nouvelle expérience définie avant examen des rendements.

5.7 Enseignements et conditions d’utilisation

J’ai relié les risques du tableau 5.12 aux difficultés observées dans le prototype et aux extensions envisagées. La mémoire et les échanges libres entre agents, notamment, restent à évaluer.

TABLE 5.12. Risques agentiques, contrôles et responsabilités.

Risque	Exemple	Conséquence	Contrôle	Responsable
Hallucination	Source inexistante ou chiffre mal interprété.	Décision fondée sur une information fausse.	Récupération sourcée, validation des citations, blocage si source invalide.	Conformité
Surapprentissage narratif	Explication convaincante d’un signal non robuste.	Confusion entre récit et preuve financière.	Séparation temporelle, coûts, benchmark et tests de sensibilité.	Quant et risque
Permission excessive	Agent autorisé à modifier les poids ou à appeler l’exécution.	Action non validée et difficile à annuler.	Permissions minimales, outils déterministes et validation humaine.	IT et risque
Dépendance au modèle	Réponse différente après changement de version.	Décision non reproductible ou dérive de comportement.	Versionnement des modèles, prompts, données, outils et sorties.	Propriétaire IA
Désaccord non traité	Agents risque et portefeuille produisent des avis incompatibles.	Consensus artificiel et perte d’un signal d’alerte.	Conservation des avis, escalade et décision humaine explicite.	Superviseur

Le dépassement du turnover a été observé dans les propositions d’allocation et bloqué par Python. L’acceptation d’une citation inexistante provient, elle, d’un contre-exemple construit pour éprouver le validateur de synthèse. Ces deux cas justifient de conserver les chiffres

sources et les motifs de validation.

L'usage d'un fournisseur externe demande de classer les données transmises, d'examiner leur conservation, leur localisation et les conditions contractuelles. Un changement de modèle ou une interruption de l'API peut modifier le comportement ; le mode sans LLM et la conservation des positions fournissent ici des replis déterministes. Les instructions adverses présentes dans des documents ou données restent un risque à tester si de nouvelles sources sont intégrées.

Avant une utilisation réelle, je testerais d'abord le système en mode observation, avec une revue indépendante des contrôles de risque, des permissions et des journaux par les fonctions risque, conformité et IT. Il faudrait également mesurer le temps consacré à la revue humaine et son coût.

Chapitre 6

Conclusion

6.1 Ce que je retiens du prototype

J’ai examiné les contrôles des synthèses et des allocations proposées par le LLM.

Le backtest m’a fourni le socle de cette comparaison : l’équipondération des quatre ETF reste derrière SPY en rendement annualisé, après frais de transaction. Le contrôle sur 2021–2025 conserve ce classement. J’y vois un cas reproductible pour l’étude de la couche agentique, sans supériorité financière du multifactoriel.

Les synthèses DeepSeek satisfont les contrôles automatisés, mais trois altérations construites passent aussi le validateur : coût inexact, citation inexistante et recommandation contradictoire. Ces essais m’ont conduit à examiner ce que le validateur laisse passer, au-delà du taux d’acceptation. La fiabilité du texte et son utilité pour un analyste demanderaient également une lecture indépendante.

Dans l’extension d’allocation, DeepSeek termine derrière l’équipondération et l’inverse volatilité, après frais de transaction. Sur 56 propositions, 34 sont rejetées, surtout pour dépassement du turnover. Je retiens ici l’utilité du contrôle, qui bloque des propositions incorrectes. Le rendement obtenu dépend aussi de ces rejets et de la conservation des positions qu’ils déclenchent : il évalue l’ensemble du dispositif.

Ce travail m’a ainsi conduit à déplacer la question initiale : l’enjeu n’est pas seulement de savoir ce qu’un LLM peut produire pour un desk, mais surtout ce que le système est capable de vérifier avant d’utiliser cette production.

6.2 Limites de portée

Le PnL d'allocation reste rétrospectif : les indicateurs sont coupés dans le temps, mais le préentraînement peut contenir les événements étudiés. Une seule trajectoire a été collectée et les données ne sont pas disponibles dans leurs versions historiques point-in-time. Le replay et les 46 tests établissent la cohérence technique, sans démontrer la généralisation financière.

Je conserve également une réserve sur le bilan des coûts : le PnL exclut l'API, l'infrastructure et le travail humain. Les 66 014 jetons connus, auxquels peut s'ajouter l'usage de la requête interrompue, documentent une consommation partielle. La facture, le coût total d'exploitation et les gains éventuels de temps restent à mesurer.

6.3 Deux suites prioritaires

Je renforcerais d'abord la fiabilité des sorties : tolérances adaptées aux champs, citations exactes et cohérence du texte pour les notes ; choix parmi des portefeuilles déjà admissibles pour l'allocation. Ce dernier dispositif serait comparé à une règle utilisant les mêmes indicateurs, selon un protocole défini avant observation des rendements puis suivi prospectivement.

Je comparerais ensuite les notes auprès d'analystes sur plusieurs dates, en faisant varier l'ordre de présentation. L'exactitude des réponses, la détection des alertes et le temps nécessaire seraient rapprochés des coûts API et de revue, pour évaluer la valeur pratique de cette intégration.

Bibliographie

AI4Finance Foundation (2026a). FinGPT : Open-Source Financial Large Language Models. <https://github.com/AI4Finance-Foundation/FinGPT>. Consulté le 30 août 2026.

AI4Finance Foundation (2026b). FinRL : Financial reinforcement learning. <https://github.com/AI4Finance-Foundation/FinRL>. Consulté le 30 août 2026.

AI4Finance Foundation (2026c). FinRL-Meta : Market environments and benchmarks for financial reinforcement learning. <https://github.com/AI4Finance-Foundation/FinRL-Meta>. Consulté le 30 août 2026.

AI4Finance Foundation (2026d). FinRobot : An Open-Source AI Agent Platform for Financial Analysis using LLMs. <https://github.com/AI4Finance-Foundation/FinRobot>. Consulté le 30 août 2026.

Aroussi, R. (2026). yfinance : Yahoo Finance market data downloader. <https://github.com/ranaroussi/yfinance>. Consulté le 30 août 2026; utilisé pour le prototype reproductible.

CAMEL-AI (2026). CAMEL : Multi-agent framework. <https://github.com/camel-ai/camel>. Consulté le 30 août 2026.

Carhart, M. M. (1997). On Persistence in Mutual Fund Performance. *The Journal of Finance*, 52(1) :57-82.

CrewAI Inc. (2026). CrewAI : Framework for orchestrating role-playing autonomous AI agents. <https://github.com/crewAIInc/crewAI>. Consulté le 30 août 2026.

- DeepSeek (2026). Thinking Mode : API Documentation. https://api-docs.deepseek.com/guides/thinking_mode/. Consulté le 12 septembre 2026; paramètre explicite de désactivation utilisé dans la campagne d'allocation.
- European Parliament and Council of the European Union (2022). Regulation (EU) 2022/2554 on digital operational resilience for the financial sector. <https://eur-lex.europa.eu/eli/reg/2022/2554/oj>. Consulté le 30 août 2026.
- European Parliament and Council of the European Union (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence. <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>. Consulté le 30 août 2026.
- European Securities and Markets Authority (2026). MiFID II, Article 17 : Algorithmic trading. <https://www.esma.europa.eu/publications-and-data/interactive-single-rulebook/mifid-ii/article-17-algorithmic-trading>. Consulté le 30 août 2026.
- Fama, E. F. et French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1) :3-56.
- FinMem contributors (2026). FinMem-LLM-StockTrading. <https://github.com/pipiku915/FinMem-LLM-StockTrading>. Consulté le 30 août 2026.
- Freqtrade (2026). Freqtrade : Free, open source crypto trading bot. <https://github.com/freqtrade/freqtrade>. Consulté le 30 août 2026.
- LangChain AI (2026). LangGraph : Low-level orchestration framework for building stateful agents. <https://github.com/langchain-ai/langgraph>. Consulté le 30 août 2026.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., et Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. <https://arxiv.org/abs/2005.11401>.
- Microsoft (2026a). AutoGen : A programming framework for agentic AI. <https://github.com/microsoft/autogen>. Consulté le 30 août 2026.

- Microsoft (2026b). Qlib : AI-oriented quantitative investment platform. <https://github.com/microsoft/qlib>. Consulté le 30 août 2026.
- Microsoft (2026c). Semantic Kernel. <https://github.com/microsoft/semantic-kernel>. Consulté le 30 août 2026.
- OpenAI (2026). Swarm : Educational framework exploring lightweight multi-agent orchestration. <https://github.com/openai/swarm>. Consulté le 30 août 2026.
- OpenBB Finance (2026). OpenBB : Financial data platform for analysts, quants and AI agents. <https://github.com/OpenBB-finance/OpenBB>. Consulté le 30 août 2026.
- Patel, V. (2026). AI Hedge Fund. <https://github.com/virattt/ai-hedge-fund>. Consulté le 30 août 2026.
- QuantConnect (2026). Lean Algorithmic Trading Engine. <https://github.com/QuantConnect/Lean>. Consulté le 30 août 2026.
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., et Scialom, T. (2023). Toolformer : Language Models Can Teach Themselves to Use Tools. <https://arxiv.org/abs/2302.04761>.
- Shinn, N., Cassano, F., Berman, E., Gopinath, A., Narasimhan, K., et Yao, S. (2023). Reflexion : Language Agents with Verbal Reinforcement Learning. <https://arxiv.org/abs/2303.11366>.
- Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). Rapport technique NIST AI 100-1, National Institute of Standards and Technology. Consulté le 30 août 2026 ; la page officielle indique une révision de l'AI RMF 1.0.
- Tauric Research (2026). TradingAgents : Multi-Agents LLM Financial Trading Framework. <https://github.com/TauricResearch/TradingAgents>. Consulté le 30 août 2026.
- Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., et Wang, C. (2023). AutoGen : Enabling

- Next-Gen LLM Applications via Multi-Agent Conversation. <https://arxiv.org/abs/2308.08155>.
- Yang, H., Liu, X.-Y., et Wang, C. D. (2023). FinGPT : Open-Source Financial Large Language Models. <https://arxiv.org/abs/2306.06031>.
- Yang, H., Zhang, B., She, Y., Liao, X., et Zhang, X. (2026). FinRL-X : An AI-Native Modular Infrastructure for Quantitative Trading. <https://arxiv.org/abs/2603.21330>.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., et Cao, Y. (2023). ReAct : Synergizing Reasoning and Acting in Language Models. <https://arxiv.org/abs/2210.03629>.
- Yu, Y., Li, H., Chen, Z., Jiang, Y., Li, Y., Zhang, D., Liu, R., Suchow, J. W., et Khashanah, K. (2023). FinMem : A Performance-Enhanced LLM Trading Agent with Layered Memory and Character Design. <https://arxiv.org/abs/2311.13743>.

Annexe I

Due diligence des solutions retenues

Relevé des huit dépôts au 30 août 2026. L'activité observée ne garantit ni la maintenance ni l'aptitude à la production ; licences et dépendances demandent une revue actualisée. Le statut d'utilisation figure au chapitre 2.

TABLE I.1. Grille de due diligence des briques sélectionnées.

Dépôt	Licence	Dernier push	Docs et tests	Sécurité	Avis provisoire
LangGraph (LangChain AI, 2026)	MIT	30/08/2026	README, docs ; tests à inspecter	Politique présente	Orchestration active ; audit dépendances.
Qlib (Microsoft, 2026b)	MIT	23/07/2026	docs, tests	SECURITY.md	Brique quantitative documentée.
Lean (QuantConnect, 2026)	Apache-2.0	28/08/2026	README, Tests	À vérifier	Moteur actif ; audit des données.
OpenBB (OpenBB Finance, 2026)	AGPLv3*	30/07/2026	README, pytest.ini	SECURITY.md	Licence à valider juridiquement.
TradingAgents (Tauric Research, 2026)	Apache-2.0	30/08/2026	README, tests	À vérifier	Prototype multi-agents.
FinRobot (AI4Finance Foundation, 2026d)	Apache-2.0	23/08/2026	README, test_module.py	À vérifier	Démonstrateur financier.
FinRL (AI4Finance Foundation, 2026b)	MIT	13/07/2026	docs, unit_tests	À vérifier	RL ; surapprentissage à contrôler.
Freqtrade (Freqtrade, 2026)	GPL-3.0	27/08/2026	docs, tests	À vérifier	Bot crypto ; périmètre différent.

* OpenBB : README AGPLv3, API GitHub NOASSERTION. Divergence à examiner juridiquement. Relevé structuré : [github_due_diligence.json](#).

Annexe II

Reproduction de l'expérience d'allocation

L'expérience du 12 septembre 2026 est conservée dans `results/allocation_experiment/`. Le code, le prompt et les données utilisés sont identifiés par les empreintes de `deepseek/report.json`. Les réponses restent consultables dans `deepseek_decisions.json`. La reproduction locale ne nécessite ni clé API ni connexion réseau.

II.1 Fichiers et vérifications

Propositions et exécution : `deepseek/decisions.json` contient les entrées, propositions, quantités avant/après, dates d'exécution, frais et rejets des trois politiques.

Valeurs et indicateurs : `deepseek/equity.csv`, `deepseek/metrics.csv` et `yearly_returns.csv` fournissent les séries et résultats numériques.

Essais techniques : `technical_pilot_default_thinking.json` conserve les quatre tentatives précédant la campagne corrigée ; elles ne sont pas fusionnées avec ses 56 décisions.

Audit : `AUDIT.json` conserve les écarts comptables, l'identité du replay et le contrôle des 31 fichiers antérieurs. Le manifeste correspondant est `original_inputs_sha256.json`.

Documentation : `PROTOCOLE.md` et `ANALYSE.md` détaillent conventions, résultats et limites.

II.2 Commandes de reproduction sans appel API

Depuis la racine du projet, la commande suivante relit les réponses archivées et calcule les positions :

```
experience/.venv/bin/python agent_allocation_backtest.py
--mode replay --start 2021-05-01
--archive results/allocation_experiment/deepseek_decisions.json
--max-output-tokens 3000
--output results/allocation_experiment/replay
```

Les lignes sont présentées séparément pour la lecture ; la commande s'exécute sur une seule ligne. Les paramètres de coûts et de fin de période prennent leurs valeurs par défaut, 10 points de base et le 31 décembre 2025. Toute différence de contexte par rapport à une requête archivée interrompt le replay.

La vérification comptable et la suite de tests s'exécutent ensuite avec :

```
experience/.venv/bin/python analyze_allocation_results.py
experience/.venv/bin/python -m pytest -q
```

Le mode live, décrit dans le [README](#), nécessite une clé et un budget explicite. Il réutilise les dates de son archive et compte toutes les tentatives, y compris les interruptions. Rejouer les archives n'envoie pas de nouvel appel ; une nouvelle expérience avec un autre prompt ou d'autres contraintes doit utiliser une archive distincte et un budget identifié.