



L'approche agentique dans un contexte de trading multifactoriel

Prototype supervisé et évaluation d'une synthèse LLM

SANOU Abou Dramane

Master Finance de marché · CNAM

Encadrant : Bertrand DJEMBISSI

Septembre 2026

Une synthèse utile doit rester vérifiable

Question de recherche

Comment intégrer des agents LLM au trading multifactoriel tout en conservant des calculs reproductibles, des permissions explicites et une trace vérifiable ?

- Le moteur quantitatif calcule les rendements et les poids.
- La couche agentique restitue les résultats et les alertes.
- La validation humaine reste requise.

Le prototype évalue une aide à l'analyse supervisée.

Trois étapes pour répondre à la question

1. Comparer les briques disponibles
Revue documentaire : 17 fiches, dont 8 dépôts approfondis.
2. Construire un prototype reproductible
Quatre ETF factoriels, un benchmark et une synthèse supervisée.
3. Évaluer les résultats et leurs limites
Backtest, 33 réponses LLM, comparaison des notes et contre-exemples.

Source : Mémoire, méthodologie et résultats expérimentaux.

La revue sépare les responsabilités

Rôle étudié	Exemples du corpus	Enseignement retenu
Orchestration	LangGraph, AutoGen	Organiser les tâches et l'état.
Socle quantitatif	Qlib, Lean	Garder les calculs dans des outils dédiés.
Agents financiers	TradingAgents, FinRobot	Examiner les rôles et les synthèses.

Choix du prototype : calculs Python et orchestration LangGraph.

Source : Mémoire, revue et grille documentaire ; appréciation de l'auteur.

Quatre expositions, une allocation fixe

Exposition	ETF	Poids
Value	VLUE	25 %
Momentum	MTUM	25 %
Quality	QUAL	25 %
Low volatility	USMV	25 %

- Benchmark : SPY.
- Rééquilibrage mensuel.
- Cours ajustés via yfinance.
- Rendements : fév. 2015–déc. 2025.
- Contrôle temporel : 2021–2025.

Les ETF sont des proxies investissables des facteurs.

Source : Mémoire, protocole expérimental; paramètres du backtest.

Les coûts dépendent du rééquilibrage

$$r_t^{\text{net}} = \sum_i w_{i,t-1} r_{i,t} - c\tau_t, \quad \tau_t = \frac{1}{2} \sum_i |w_{i,t}^{\text{cible}} - w_{i,t}^{\text{après}}|$$

- Trois coûts unitaires : 0, 10 et 30 points de base.
- Turnover « one-way » : achats ou ventes, sans double comptage.
- Prix de fin de mois théoriques; coût initial exclu.
- Sharpe calculé avec un taux sans risque fixé à zéro.

Les hypothèses d'exécution limitent la portée du backtest.

Le LLM intervient après les calculs

1. Backtest déterministe : rendements, poids, coûts, diagnostics.
2. Workflow LangGraph : lecture des fichiers, qualité et risque.
3. Restitution : note déterministe ou synthèse LLM en JSON.
4. Vérification : valeurs, structure et permissions déclarées.
5. Sorties : note de revue et trace JSON.

Le programme n'expose aucun outil d'envoi d'ordres au LLM.

Le prototype a un périmètre explicite

Implémenté

- Calculs et diagnostics archivés.
- Notes déterministes et option LLM.
- Cas qualité bloqué avant appel LLM.
- Alertes et permissions déclarées.

À développer

- Moteur complet de limites et de liquidité.
- Approbation humaine enregistrée.
- Audit historique entièrement versionné.
- Validation auprès d'analystes.


SPY conserve l'avantage sur 2015--2025

Indicateur	Multifactoriel, 10 pb	SPY
Rendement annualisé	12,02 %	13,84 %
Volatilité annualisée	14,17 %	14,96 %
Sharpe (taux sans risque nul)	0,875	0,946
Drawdown maximal	−23,85 %	−23,93 %
Valeur finale, base 100	345,10	411,73

Une volatilité plus faible, sans supériorité financière démontrée.

Source : results/metrics.csv; mémoire, résultats du backtest.

L'écart de richesse se creuse dans le temps



Base 100 : 411,73 pour SPY contre 345,10 pour le multifactoriel à 10 pb.

Source : Figure du mémoire; results/wealth.csv et results/metrics.csv.

Le contrôle temporel confirme le classement

2021–2025 : rendement annualisé

11,25 % : multifactoriel à 10 pb

14,34 % : SPY

- Volatilité : 14,37 % contre 15,14 %.
- Aucun paramètre entraîné avant 2021.
- Le contrôle teste une autre période.

Sensibilité aux coûts, 2015–2025 : le rendement annualisé passe de 12,02 % à 12,00 % entre 0 et 30 pb.

Source : [results/period_metrics.csv](#) et [results/metrics.csv](#).

L'évaluation LLM porte sur 12 cas

- 10 dates historiques.
- 1 stress de turnover élevé.
- 1 cas qualité bloqué sans appel API.

33 réponses archivées

11 cas non bloqués
× 3 répétitions par cas

Modèle enregistré : **deepseek-v4-flash**.

Expérience archivée le 7 septembre 2026.

Les répétitions mesurent la variabilité sur les mêmes situations.

Tous les contrôles passent, avec des limites

Mesure du protocole	Résultat
Conformité numérique à la tolérance fixée	100 %
Conformité des booléens de permission	100 %
Stabilité des chiffres normalisés et permissions	100 %
Stabilité de l'ensemble exact des champs cités	0 %

- La sélection des citations varie pour chacun des 11 cas répétés.
- Ces contrôles ne valident pas intégralement le texte libre.

Source : `results/deepseek_evaluation.json`; mémoire, évaluation automatisée.

Même état, deux façons de le restituer

31 décembre 2025 · première répétition du cas historique correspondant

Note déterministe : extraits

Value : +2.90 %

Momentum : +0.29 %

Quality : +0.58 %

Low volatility : **-0.82 %**

Rendement net : +0.74 %

Turnover : +0.54 %

Synthèse LLM : extrait

« Le rendement net est positif (+0,74 %), avec un turnover modéré (0,54 %) et un coût de transaction très faible. Le statut de risque reste à valider. »

Le LLM reformule; ses qualificatifs n'ont pas de seuil défini.

Source : results/note_comparison.md ; mémoire, comparaison des notes.

L'utilité pour l'analyste reste à mesurer

Critère	Constat sur la comparaison
Exactitude	Valeurs structurées conformes aux contrôles.
Clarté	Reformulation lisible; qualificatifs non calibrés.
Alertes	Présentes; exhaustivité à vérifier.
Traçabilité	Sources disponibles, sélection des citations variable.
Valeur d'usage	Aucun test utilisateur, aucun gain de temps établi.

Une comparaison exploratoire, sans note globale de qualité.

Source : Mémoire, grille critique et discussion de l'utilité; comparaison sur une date.

Trois erreurs construites passent le validateur

Altération indépendante	Faiblesse mise en évidence	Score
Coût remplacé par zéro	Tolérance trop large pour ce champ.	Accepté
Citation d'un champ inventé	Préfixe reconnu, chemin non vérifié.	Accepté
Ordre sans validation humaine	Texte contraire aux permissions.	Accepté

Deux témoins rejetés : permission d'ordre; rendement net majoré de 1 point de pourcentage.

Essais manuels sur une réponse archivée; aucune fréquence d'erreur estimée.

Source : [results/complementary_analysis.json](#); [analyze_note_comparison.py](#).

Trois améliorations prioritaires

1. Renforcer la validation des notes
Tolérances par champ, chemins sources exacts, cohérence du texte libre.
2. Compléter la traçabilité et la supervision
Prompts et données versionnés, décision humaine enregistrée.
3. Mesurer l'utilité en situation de travail
Comparer temps, exactitude et détection d'alertes sur plusieurs dates.

Source : Mémoire, analyse complémentaire, limites et conclusion.

Une contribution d'intégration et d'évaluation


Résultat principal

Le prototype relie des calculs reproductibles à une synthèse supervisée et rend inspectables les limites de ses contrôles.

- Le socle quantitatif ne démontre pas de surperformance.
- Le LLM reformule; son utilité reste à mesurer.
- Les contre-exemples précisent les validations à renforcer.

Merci pour votre attention.

Annexe · Les pertes maximales restent proches



Drawdown maximal : $-23,85\%$ à 10 pb contre $-23,93\%$ pour SPY.

Source : Figure du mémoire; results/drawdowns.csv et results/metrics.csv.

Annexe · Pourquoi le coût nul est accepté

- Coût réel du 31/12/2025 en fraction : $5,362 \times 10^{-6}$.
- Tolérance absolue du validateur : 10^{-4} .
- L'écart avec zéro est inférieur à la tolérance.

$$|0 - 0,000005362| < 0,0001$$

La précision attendue doit dépendre de l'échelle du champ.

Source : results/complementary_analysis.json; code du validateur.

Annexe · Sources et reproductibilité

- Mémoire : chapitres 3 à 6, protocole et analyse critique.
- Finance : `metrics.csv`, `period_metrics.csv`.
- Archive LLM : `deepseek_evaluation.json`.
- Notes : `note_comparison.md`.
- Contre-exemples : `complementary_analysis.json`.

Rejouer l'analyse complémentaire, sans appel API :

```
experience/.venv/bin/python analyze_note_comparison.py
```

Source : Fichiers du projet; valeurs issues des résultats archivés.