



L'approche agentique dans un contexte de trading multifactoriel

Synthèse LLM et allocation de portefeuille sous contraintes

SANOU Abou Dramane

Master Finance de marché · CNAM

Encadrant : Bertrand DJEMBISSI

Septembre 2026

Synthèse et allocation sous contrôle

Question de recherche

Comment utiliser les sorties d'un LLM dans une chaîne multifactorielle tout en pouvant vérifier ses chiffres, ses sources et ses décisions?

- Synthèse : restituer un état quantitatif déjà calculé.
- Allocation : proposer des poids soumis aux contrôles Python.
- Évaluation : comparer les notes, puis le PnL simulé.

Le moteur déterministe conserve le calcul et le contrôle des positions.

Démarche de recherche

1. Revue et choix des composants
17 fiches documentaires, dont 8 dépôts approfondis.
2. Synthèse de résultats financiers
Backtest ETF, 33 réponses LLM et contre-exemples du validateur.
3. Allocation sous contraintes
56 propositions, deux règles de référence et replay hors réseau.

Source : Mémoire, chapitres 2, 3 et 5.

La revue sépare les responsabilités

Rôle étudié	Exemples du corpus	Enseignement retenu
Orchestration	LangGraph, AutoGen	Organiser les tâches et l'état.
Socle quantitatif	Qlib, Lean	Garder les calculs dans des outils dédiés.
Agents financiers	TradingAgents, FinRobot	Examiner les rôles et les synthèses.

Choix du prototype : calculs Python et orchestration LangGraph.

Source : Mémoire, revue et grille documentaire ; appréciation de l'auteur.

Socle initial : quatre ETF équipondérés

Exposition	ETF	Poids
Value	VLUE	25 %
Momentum	MTUM	25 %
Quality	QUAL	25 %
Low volatility	USMV	25 %

- Benchmark : SPY.
- Rééquilibrage mensuel, coûts de 0, 10 et 30 pb.
- Cours ajustés via yfinance.
- Rendements : fév. 2015–déc. 2025.
- Contrôle temporel : 2021–2025.

Les ETF sont des proxies investissables des facteurs.

Source : Mémoire, protocole expérimental; paramètres du backtest.

Composants exécutés et architecture proposée

	Synthèse	Allocation simulée
Rôle du LLM	Résumer les résultats	Proposer les poids cibles
Programme	LangGraph et superviseur déterministe	Module Python distinct
Contrôles	Qualité, chiffres, permissions déclarées	Poids, turnover, sources et exécution
Effet d'un rejet	Sortie rejetée et archivée	Conservation des quantités détenues

Les sept rôles de l'architecture cible ne sont pas tous exécutés.

Source : Mémoire, chapitre 4 et protocole d'allocation.

SPY conserve l'avantage sur 2015--2025

Indicateur	Multifactoriel, 10 pb	SPY
Rendement annualisé	12,02 %	13,84 %
Volatilité annualisée	14,17 %	14,96 %
Sharpe (taux sans risque nul)	0,875	0,946
Drawdown maximal	−23,85 %	−23,93 %
Valeur finale, base 100	345,10	411,73

Sur 2021–2025, le classement reste le même : 11,25 % contre 14,34 %.

Source : results/metrics.csv; mémoire, résultats du backtest.

Synthèse : 33 réponses passent les contrôles

12 cas : 10 dates, un stress de turnover et un cas qualité bloqué.

Les 11 cas non bloqués donnent 3 répétitions, soit 33 réponses.

Mesure automatisée	Résultat
Conformité numérique et booléens de permission	100 %
Stabilité des chiffres normalisés et permissions	100 %
Stabilité de l'ensemble exact des champs cités	0 %

Ces scores couvrent les contrôles retenus, pas tout le texte libre.

Même état, deux façons de le restituer

31 décembre 2025 · première répétition du cas historique correspondant

Note déterministe : extraits

Value : +2.90 %

Momentum : +0.29 %

Quality : +0.58 %

Low volatility : **−0.82 %**

Rendement net : +0.74 %

Turnover : +0.54 %

Synthèse LLM : extrait

« Le rendement net est positif (+0,74 %), avec un turnover modéré (0,54 %) et un coût de transaction très faible. Le statut de risque reste à valider. »

Le LLM reformule; ses qualificatifs n'ont pas de seuil défini.

Trois erreurs construites passent le validateur

Altération indépendante	Faiblesse mise en évidence	Score
Coût remplacé par zéro	Tolérance trop large pour ce champ.	Accepté
Citation d'un champ inventé	Préfixe reconnu, chemin non vérifié.	Accepté
Ordre sans validation humaine	Texte contraire aux permissions.	Accepté

Deux témoins rejetés : permission d'ordre; rendement net majoré de 1 point de pourcentage.

Essais construits sur une réponse archivée; aucune fréquence d'erreur estimée.

Source : `complementary_analysis.json`; `analyze_note_comparison.py`.

Allocation : 56 décisions mensuelles

- Mai 2021–décembre 2025. Base 100 au 30 avril 2021, déjà investie à 25 % dans chaque ETF.
- Trois politiques : équipondération, inverse volatilité et DeepSeek.
- Contraintes communes : poids de 0 à 40 %, somme à 100 %, turnover maximal de 10 %.
- Exécution différée : première clôture du mois suivant, frais de 10 pb par unité de turnover, valorisation quotidienne.

Un rejet conserve les quantités, sans nouvelle proposition ni transaction.

DeepSeek termine derrière les deux références


Mai 2021–décembre 2025, après frais de transaction

Indicateur	Équipondéré	Inverse vol.	DeepSeek
Capital final, base 100	153,55	152,26	148,39
PnL en unités	+53,55	+52,26	+48,39
Rendement annualisé	9,62 %	9,42 %	8,82 %
Volatilité annualisée	15,66 %	15,08 %	14,87 %
Sharpe, taux sans risque nul	0,667	0,674	0,645
Drawdown maximal	−24, 20 %	−23, 44 %	−23, 50 %

Écart avec l'équipondération : −5, 17 unités pour 100 investies.

Source : `metrics.csv`, tableau 5.7 du mémoire.

Trajectoires des trois portefeuilles



Les rejets et la conservation des positions contribuent à cette trajectoire.

Source : `equity.csv`, valeurs quotidiennes après frais.

34 propositions rejetées sur 56

22 propositions exécutées. Les deux règles de référence passent les 56 contrôles.

Motif	Occurrences
Turnover proposé supérieur à 10 % à l'observation	31
Turnover supérieur à 10 % à l'exécution, après frais	2
Somme des poids différente de 100 %	1
Poids hors limites	1
Référence à un champ absent des entrées	1

36 motifs pour 34 rejets : une réponse peut cumuler plusieurs erreurs.

Un turnover annoncé conforme vaut en réalité 20 %

Proposition du 30 avril 2021, à partir de 25 % dans chaque ETF

ETF	Initial	Proposé	Écart en points
VLUE	25 %	40 %	+15
MTUM	25 %	20 %	−5
QUAL	25 %	30 %	+5
USMV	25 %	10 %	−15

$$\tau = \frac{1}{2}(0,15 + 0,05 + 0,05 + 0,15) = 20 \% > 10 \%$$

La justification affirme respecter la limite. Python bloque la proposition.

Source : `decisions.json`, première décision.

Les calculs et le replay concordent

- 46 tests réussis, dont 23 ajoutés pour l'allocation.
- 56 décisions rejouées hors réseau, sans appel API.
- Fichiers de décisions, métriques et valorisations identiques au replay.
- 3 519 valorisations quotidiennes contrôlées, soit 1 173 par politique.
- Écart comptable maximal sur ces valorisations : $5,68 \times 10^{-14}$.

Le replay reproduit les décisions archivées et leurs conséquences comptables.

Source : `AUDIT.json`, section 5.6.4 du mémoire.

Les frais de portefeuille ne couvrent pas tout le coût

	Équipondéré	Inverse vol.	DeepSeek
Frais cumulés, base 100	0,0476	0,0708	0,0682

- 54 639 jetons pour la campagne de 56 réponses.
- 11 375 jetons connus pour les essais techniques antérieurs.
- Total connu : 66 014 jetons, plus une requête interrompue sans usage reçu.
- Le PnL exclut l'API, l'infrastructure et la revue humaine.

La consommation archivée ne fournit pas une facture complète.

Une expérience historique à portée limitée

- Préentraînement : appels en septembre 2026 sur des décisions datées de 2021–2025.
- Données : cours ajustés disponibles aujourd'hui, sans versions historiques point-in-time.
- Échantillon : quatre ETF et une seule trajectoire de 56 réponses.
- Simulation : clôture suivante, frais fixes, sans modèle de spread ni d'impact.

Le résultat technique est vérifiable. La généralisation financière reste à tester.

Deux suites prioritaires

1. Renforcer la fiabilité des sorties

Notes : tolérances par champ, citations exactes, cohérence du texte.

Allocation : choix parmi des portefeuilles déjà admissibles.

Comparaison prospective avec une règle utilisant les mêmes indicateurs.

2. Mesurer l'utilité auprès d'analystes

Comparer exactitude, détection d'alertes et temps de revue.

Rapprocher les gains éventuels des coûts API et humains.

Ce que je retiens du prototype

- Le multifactoriel reste derrière SPY sur le backtest initial.
- Le validateur de synthèse accepte certains contenus faux construits pour le tester.
- L'allocation DeepSeek reste derrière les règles simples, avec 34 rejets sur 56 propositions.

Mon principal enseignement : ce que le système vérifie avant d'utiliser une sortie LLM est central dans son intégration.

Merci pour votre attention.


Annexe : coûts du backtest initial

$$r_t^{\text{net}} = \sum_i w_{i,t-1} r_{i,t} - c\tau_t, \quad \tau_t = \frac{1}{2} \sum_i \left| w_{i,t}^{\text{cible}} - w_{i,t}^{\text{après}} \right|$$

- Trois coûts unitaires : 0, 10 et 30 points de base.
- Turnover « one-way » : achats ou ventes, sans double comptage.
- Prix de fin de mois théoriques; coût initial exclu.
- Sharpe calculé avec un taux sans risque fixé à zéro.

Les hypothèses d'exécution limitent la portée du backtest.

Annexe : richesse du backtest initial



Base 100 : 411,73 pour SPY contre 345,10 pour le multifactoriel à 10 pb.

Source : Figure du mémoire; results/wealth.csv et results/metrics.csv.

Annexe : contrôle temporel 2021--2025

2021–2025 : rendement annualisé


11,25 % : multifactoriel à 10 pb

14,34 % : SPY

- Volatilité : 14,37 % contre 15,14 %.
- Aucun paramètre entraîné avant 2021.
- Le contrôle teste une autre période.

Sensibilité aux coûts, 2015–2025 : le rendement annualisé passe de 12,02 % à 12,00 % entre 0 et 30 pb.

Annexe · Les pertes maximales restent proches



Drawdown maximal : **−23,85 %** à 10 pb contre **−23,93 %** pour SPY.

Source : Figure du mémoire; results/drawdowns.csv et results/metrics.csv.

Annexe · Pourquoi le coût nul est accepté

- Coût réel du 31/12/2025 en fraction : $5,362 \times 10^{-6}$.
- Tolérance absolue du validateur : 10^{-4} .
- L'écart avec zéro est inférieur à la tolérance.

$$|0 - 0,000005362| < 0,0001$$

La précision attendue doit dépendre de l'échelle du champ.

Source : `complementary_analysis.json`; code du validateur.

Annexe : fichiers et reproduction

- Protocole et interprétation : `PROTOCOLE.md`, `ANALYSE.md`.
- Réponses LLM : `deepseek_decisions.json`.
- Contrôles : `AUDIT.json`.
- Synthèse initiale : `note_comparison.md`, `complementary_analysis.json`.

Reproduction hors réseau : commandes complètes dans le **README**.

```
experience/.venv/bin/python analyze_allocation_results.py
```

```
experience/.venv/bin/python -m pytest -q
```

Source : Dépôt GitHub du projet, artefacts publiés au commit be691b4.